Morgane Bona-Pellissier (master 2 pluriTAL) - Traduction automatique - TP2

TP 2 — Construire (et dépasser) son propre système de traduction statistique

Fil rouge de ce TP : en 1993, IBM Model 1 + un décodeur simple, c'était l'état de l'art. Vous allez le reconstruire vous-même, sur votre vrai corpus, puis mesurer exactement l'écart qui nous sépare de 2024/2025 (NLLB, LLM). Le nombre que vous allez obtenir à la fin est un vrai résultat expérimental — personne ne connaît sa valeur à l'avance pour votre corpus.

Vous allez :

1. aligner vos phrases (vous l'avez déjà fait — on réutilise l'outillage) ;
2. implémenter vous-même le E-step et le M-step de l'algorithme EM pour IBM Model 1 ;
3. en tirer un **lexique bilingue automatique** — un sous-produit réellement utilisé pour les langues peu dotées ;
4. construire un traducteur complet avec le canal bruité (modèle de traduction + modèle de langue + décodeur) ;
5. **évaluer** vos traductions (BLEU/sacreBLEU, COMET si disponible) et les comparer à NLLB-200 ou un LLM ;
6. discuter, avec vos propres exemples, de ce qui casse — et pourquoi.

Les cellules marquées `# TODO` sont à compléter. Le reste est fourni pour que vous puissiez vous concentrer sur l'algorithme, pas sur la plomberie.

0. Installation

```
# INSTALL
# Importe les bibliothèques de base (le pip est commenté : tout est déjà dans le venv).
#!pip -q install sentence-transformers sacrebleu unbabel-comet nltk datasets
import re, math, random
from collections import defaultdict, Counter
import numpy as np
random.seed(0)
```

1. Charger votre corpus

Déposez vos fichiers `src.txt` (langue source) et `tgt.txt` (langue cible, une unité par ligne). Le code cherche ces fichiers ; à défaut, il utilise un petit corpus-jouet allemand → français (inventé, pour tester que le pipeline tourne — **remplacez-le par votre corpus dès que possible**).

```
# CHARGEMENT
# Lit yi.txt et fr.txt bruts et les découpe en phrases avec wtpsplit -> phrases["yi"], phrases["fr"].
# wtpsplit est listé dans requirements.txt

import os
from wtpsplit import SaT

sat = SaT("sat-3l-sm")  # petit modèle, suffisant pour ce TP

def load_lines(path, toy):
    if os.path.exists(path):
        # encoding="utf-8-sig" permet de supprimer le caractère BOM
        with open(path, encoding="utf-8-sig") as f:
            return [l.strip() for l in f if l.strip()]
    print(f"[info] {path} introuvable — corpus-jouet utilisé.")
    return toy

# textes bruts
yi_lines = load_lines("yi.txt", [])
fr_lines = load_lines("fr.txt", [])

phrases = {}
# Les résultats seront gardés dans phrases["yi"] et phrases["fr"]
for name, lines in [("yi", yi_lines), ("fr", fr_lines)]:
    phrases[name] = [s.strip()
        # On saute les titres
        for l in lines if not l.startswith("#")
        # On supprime les * de mise en forme
        for s in sat.split(l.replace("*", ""))]

    print(f"{name}: {len(lines)} lignes -> {len(phrases[name])} phrases")

    # Afficher 3 phrasese par langue
    for s in phrases[name][:3]:
        print("   ", s)
```

```
yi: 487 lignes -> 982 phrases
    — דו־ציינט צענען ביינערנע קראָטן.
    הינטער זיי, אין אַ קרישטאַלענער צעל, דו־ציינט געשמידטע ווערטער.
    : געדענק די עצה פון אַן עלטערן
fr: 497 lignes -> 907 phrases
    — Tes dents sont des grilles d'os.
    Derrière les barreaux, dans une geôle de cristal, tes mots enchaînés.
    Souviens-toi du conseil d'un aîné : les mots coupables, qui ont versé dans ta coupe des perles empoisonnées, laisse-les sortir en liberté.
```

2. Alignement des phrases — à vous de jouer

Si vos deux fichiers ne sont **pas déjà alignés ligne à ligne** (segmentation littéraire, nombre de phrases différent…), c'est ici qu'on le corrige — exactement comme dans le TP précédent. Réutilisez la méthode qui avait le mieux marché sur votre corpus (`bertalign`, ou votre réaligneur par embeddings fait main).

```
# ALIGNEMENT 1 : alignement des paragraphes
# Retrait de la mise en forme avec "*" + omission des titres (qui commencent par "#"")
yi_par = [l.replace("*", "") for l in yi_lines if not l.startswith("#")]
fr_par = [l.replace("*", "") for l in fr_lines if not l.startswith("#")]
yi_par = [p for p in yi_par if p]   # retire les séparateurs "***" devenus vides
```

```
fr_par = [p for p in fr_par if p]
print(len(yi_par), "paragraphes yiddish /", len(fr_par), "paragraphes français")
```

```
466 paragraphes yiddish / 474 paragraphes français
```

```
# ALIGNEMENT 2 : calcul des vecteurs LaBSE de chaque paragraphe
# LaBSE transforme chaque paragraphe en vecteurs
# -> permettra de comparer le yiddish et le français sans traduire

from sentence_transformers import SentenceTransformer

embedder = SentenceTransformer("sentence-transformers/LaBSE")

def embed(sents):
    # normalize_embeddings=True ramène chaque vecteur à la longueur 1
    # Les vecteurs doivent être normalisés pour obtenir leur similarité cosinus (en 3.)
    # show_progress_bar=True affiche une barre de progression
    return embedder.encode(sents, normalize_embeddings=True, show_progress_bar=True)

emb_yi = embed(yi_par)
emb_fr = embed(fr_par)
print(emb_yi.shape, emb_fr.shape)

# Résultats obtenus :
# (466, 768) (474, 768)
```

```
(466, 768) (474, 768)
```

```
# ALIGNEMENT 3 : calcul de la matrice de similarité
# Calcul de la similarité cosinus pour comparer chaque paragraphe yiddish à chaque paragraphe français (sim[i][j])
sim = emb_yi @ emb_fr.T
print(sim.shape)

# la colonne française la plus proche pour chaque ligne yiddish
meilleur = sim.argmax(axis=1)
print("10 premiers paragraphes yiddish -> français :", meilleur[:10])
print("similarité moyenne du meilleur candidat :", sim.max(axis=1).mean().round(2))
print("écart médian de position |j - i| :", np.median(np.abs(meilleur - np.arange(len(meilleur)))))

# Résultats obtenus :
# (466, 474)
# - similarité moyenne du meilleur candidat : 0,76
# - écart médian de position |j - i| : 4.0 (10 paragraphes supplémentaires en français)
```

```
(466, 474)
10 premiers paragraphes yiddish -> français : [0 1 2 3 4 5 6 7 8 9]
similarité moyenne du meilleur candidat : 0.76
écart médian de position |j - i| : 4.0
```

```
# ALIGNEMENT 4 : meilleur chemin
# chaque paire formée ajoute sa similarité
# chaque paragraphe sauté, côté yiddish ou côté français, retire 0,3 de pénalité (penalite=0.3)
# L'algorithme peut sauter lorsque cela rapporte plus que cela ne coûte
# (p. ex. pour sauter un paragraphe en trop qui décalerait le reste de l'alignement)

def align_dp(sim, penalite=0.3):
    n, m = sim.shape
    dp = np.full((n + 1, m + 1), -np.inf)
    dp[0, 0] = 0
    back = {}
    for a in range(n + 1):
        for b in range(m + 1):
            if a == 0 and b == 0:
                continue
            best, choice = -np.inf, None
            # apparier le paragraphe yiddish a-1 avec le français b-1
            if a > 0 and b > 0 and dp[a-1, b-1] + sim[a-1, b-1] > best:
                best, choice = dp[a-1, b-1] + sim[a-1, b-1], (a-1, b-1, 'match')
            # sauter un paragraphe yiddish
            if a > 0 and dp[a-1, b] - penalite > best:
                best, choice = dp[a-1, b] - penalite, (a-1, b, 'skip_src')
            # sauter un paragraphe français
            if b > 0 and dp[a, b-1] - penalite > best:
                best, choice = dp[a, b-1] - penalite, (a, b-1, 'skip_tgt')
            dp[a, b] = best
            back[(a, b)] = choice
    # remonter le chemin depuis la dernière case
    path, a, b = [], n, m
    while (a, b) != (0, 0):
        prev = back[(a, b)]
        if prev[2] == 'match':
            path.append((prev[0], prev[1]))
        a, b = prev[0], prev[1]
    return list(reversed(path))

pairs = align_dp(sim)
print(len(pairs), "paires 1-1")
print("yiddish non appariés :", len(yi_par) - len(pairs),
      "| français non appariés :", len(fr_par) - len(pairs))

# Résultats obtenus :
# 460 paires 1-1
# yiddish non appariés : 6 | français non appariés : 14
```

```
460 paires 1-1
yiddish non appariés : 6 | français non appariés : 14
```

```
# ALIGNEMENT 5 : vérification des paires
import html
from IPython.display import display, HTML

# 1. Vue d'ensemble des scores
scores = [sim[i, j] for i, j in pairs]
print("score moyen :", np.mean(scores).round(2), "| minimum :", np.min(scores).round(2))
print("paires sous 0,5 :", sum(s < 0.5 for s in scores), "sur", len(pairs))

# 2. Quels paragraphes ont été sautés ?
yi_pris = {i for i, _ in pairs}
fr_pris = {j for _, j in pairs}
yi_saute = [i for i in range(len(yi_par)) if i not in yi_pris]
fr_saute = [j for j in range(len(fr_par)) if j not in fr_pris]
```

```
print("yiddish sautés :", yi_saute)
print("français sautés :", fr_saute)

# 3. Les 5 paires les moins sûres, côte à côte
for i, j in sorted(pairs, key=lambda p: sim[p])[:5]:
    print(f"\n--- yi[{i}] <-> fr[{j}]  (score {sim[i, j]:.2f})")
    display(HTML(f"<p dir='rtl' style='text-align:right'>{html.escape(yi_par[i][:200])}</p>"))
    print(fr_par[j][:200])


print("=== Français sautés ===")
for j in fr_saute:
    print(f"fr[{j}] : {fr_par[j][:120]}")

print()
print("=== Yiddish sautés ===")
for i in yi_saute:
    print(f"yi[{i}] :")
    display(HTML(f"<p dir='rtl' style='text-align:right'>{html.escape(yi_par[i][:120])}</p>"))

# Résultats obtenus :
# score moyen : 0.76 | minimum : 0.25
# paires sous 0,5 : 10 sur 460
```

```
score moyen : 0.76 | minimum : 0.25
paires sous 0,5 : 10 sur 460
yiddish sautés : [22, 52, 84, 142, 144, 461]
français sautés : [25, 59, 70, 77, 194, 198, 203, 208, 233, 284, 349, 353, 440, 465]

--- yi[18] <-> fr[18]  (score 0.25)
```

גרינקייט פון טונקעלע יאָדלעס דורך אַ נעפל ;

```
Vert de sombres sapins à travers la brume…

--- yi[326] <-> fr[331]  (score 0.28)
```

זענע ווײַס פלאָקן.

```
Ses paupières éclatent.

--- yi[20] <-> fr[20]  (score 0.28)
```

גרינקייט פון מאָכיקע שטיינער אין אַ רעגן ;

```
Vert de pierres moussues sous la pluie…

--- yi[111] <-> fr[112]  (score 0.34)
```

נאָכאָל, טאָטעניו, קומט סקילה דעם גאונס קלויז ? און הלמאי קומט שׂריפה דעם ביימעלע אויפן טוויער ?

```
Pour quelle raison, mon Dieu, a-t-il été condamné à la lapidation, l’oratoire du Gaon ? Et pour quel crime a-t-il été puni par le feu, le petit arbre du portail ?

--- yi[19] <-> fr[19]  (score 0.37)
```

גרינקייט פון אַ וואָלקן מיט געפלאָצטער גאַל ;

```
Vert d’un nuage crevé déversant sa bile…
=== Français sautés ===
fr[25] : Verts déferlant en flots de verts. Corps contre corps.
fr[59] : — Oh, ce n’est pas cela que je voulais dire, je vous assure !
fr[70] : Et elle raconte :
fr[77] : La nuit, dans le secret de son cabinet, il ôtait son nez de caoutchouc pour pouvoir respirer plus librement et écrivait
fr[194] : Cette poignée d’ombres s’enfonce toujours plus avant dans les marais.
fr[198] : Les corps fumants évaporent leur chaleur humide et les vêtements, hérissés de fines aiguilles de glace, collent à la pea
fr[203] : Une pensée fugitive me traverse l’esprit :
fr[208] : Avoue, tu avais ensorcelé cet anneau, et mon amour n’a cessé de brûler d’un feu aussi ardent que son rubis. C’est mon an
fr[233] : Autour du corps les vêtements — dépenaillés, effilochés, en mèches ondulant au vent.
fr[284] : Et Joachim plante sa cognée dans l’arbre.
fr[349] : Et tout à coup — un loup, un loup vert crépitant d’étincelles, son ombre entre les dents, court à notre poursuite, court
fr[353] : Une même étoile les avait protégés tous deux lorsque le chasseur de chiens avait pris le gamin en pitié et l’avait caché
fr[440] : Et il continue, encore et encore, à raser le bourreau, jusqu’au jour où il réussit, Bomke, alors que l’autre fait la fêt
fr[465] : Un médecin du nom de Cyrulnik lui posa un œil de verre, aussi bleu et presque aussi gros qu’un gésier de poulet. Et à pl

=== Yiddish sautés ===
yi[22] :
```

גרינקייט פון קרויטבלעטער אין שפליטערס טוי, וואָס צעבלוטיקן פינגער ;

```
yi[52] :
```

די שטילקייט איז זיך צעלאָפן איבערן דיל, ווי קוועקזילבער פון אַ געפלאַצטן טערמאָמעטער.

```
yi[84] :
```

וווּל איך, ליבער מענטש, וועל שוין לאַנג ניט צייַן, וועל ניין באַגעגענען די צוויי מיידלעך... גיט אַ האַנט, אַז איר וועט א

```
yi[142] :
```

אַ ציטער נעמט דורך דאָס ביידעמל, ווי אַ נעסט בײַם דערפילן אַ זעג.

```
yi[144] :
```

איבער געסלעך ווי היילן פון גיפטער — זון. זון. זון.

```
yi[461] :
```

שאַ. אָט וואַנדערט זײַן רידל איבער אים. וואַנדערט אַליין צווישן הענגענדיקע פונקען. זי גראָבט, זײַן רידל, דעם קלינגענדיקן

```
# ALIGNEMENT 6 : écriture de src.txt (yiddish) et tgt.txt (français)
src_aligne = [yi_par[i] for i, j in pairs]
tgt_aligne = [fr_par[j] for i, j in pairs]

# une paire par ligne (= pas de retour à la ligne au sein d'un paragraphe)
assert all("\n" not in p for p in src_aligne + tgt_aligne)
assert len(src_aligne) == len(tgt_aligne)
```

```
with open("src.txt", "w", encoding="utf-8") as f:
    f.write("\n".join(src_aligne) + "\n")
with open("tgt.txt", "w", encoding="utf-8") as f:
    f.write("\n".join(tgt_aligne) + "\n")

# Reconstruction de src_sents / tgt_sents
src_sents, tgt_sents = src_aligne, tgt_aligne
print(len(src_aligne), "paires écrites dans src.txt et tgt.txt")
```

```
460 paires écrites dans src.txt et tgt.txt
```

```
# RECHARGEMENT & JEU DE TEST
# Recharge src.txt et tgt.txt dans src_sents / tgt_sents et vérifie qu'ils sont alignés.
# toy seront utilisés comme fichiers src et tgt si les fichiers fournis ne pointent nulle part.

toy_src = [
    "das Haus ist groß", "das Buch ist alt", "die Katze schläft", "der Hund läuft",
    "das Kind liest das Buch", "die Frau kauft das Haus", "der Mann liest die Zeitung",
    "das Mädchen sieht die Katze", "der Hund sieht das Kind", "die Frau liest das Buch",
]
toy_tgt = [
    "la maison est grande", "le livre est vieux", "le chat dort", "le chien court",
    "l'enfant lit le livre", "la femme achète la maison", "l'homme lit le journal",
    "la fille voit le chat", "le chien voit l'enfant", "la femme lit le livre",
]

src_sents = load_lines("src.txt", toy_src)
tgt_sents = load_lines("tgt.txt", toy_tgt)

assert len(src_sents) == len(tgt_sents), "src et tgt doivent avoir le même nombre de lignes : alignez-les d'abord (section 2) !"
print(len(src_sents), "paires de phrases chargées.")


# Jeu de test mis à l'écart de l'entraînement
N_TEST = 30
random.seed(0)   # tirage reproductible

# candidats : paires de 5 à 30 mots dans les deux langues
# candidats = les numéros k des paires (yiddish, français) qui peuvent servir de test
candidats = [k for k in range(len(src_sents))               # k parcourt les numéros de toutes les paires
             if 5 <= len(src_sents[k].split()) <= 30        # phrase yiddish de 5 à 30 mots (split() compte les mots séparés par des espaces)
             and 5 <= len(tgt_sents[k].split()) <= 30]      # ET phrase française de 5 à 30 mots

test_idx = set(random.sample(candidats, N_TEST))

test_src = [src_sents[k] for k in sorted(test_idx)]
test_ref = [tgt_sents[k] for k in sorted(test_idx)]

# l'entraînement ne voit plus ces paires
src_sents = [s for k, s in enumerate(src_sents) if k not in test_idx]
tgt_sents = [s for k, s in enumerate(tgt_sents) if k not in test_idx]
print(len(src_sents), "paires d'entraînement /", len(test_src), "paires de test")

# Résultat obtenu :
# "460 paires de phrases chargées.
# 430 paires d'entraînement / 30 paires de test"
```

```
460 paires de phrases chargées.
430 paires d'entraînement / 30 paires de test
```

3. Tokenisation et vocabulaire

```
# TOKENISATION

def tokenize(s):
    # split() coupe uniquement aux espaces
    #return s.lower().split()

    s = s.lower()

    # points de suspension
    s = re.sub(r"\.{2,}", "…", s)

    # élisions
    s = re.sub(r"\b(l|d|j|t|m|s|n|c|qu|jusqu|lorsqu|puisqu)(['’])(?=\w)", r"\1\2 ", s)

    # ponctuation : de chaque côté de chaque signe
    s = re.sub(r"([.,;:!?…«»()\[\]\"“”„—])", r" \1 ", s)
    return s.split()

src_tok = [tokenize(s) for s in src_sents]
tgt_tok = [tokenize(s) for s in tgt_sents]

src_vocab = sorted(set(w for s in src_tok for w in s))
tgt_vocab = sorted(set(w for s in tgt_tok for w in s)) + ["<NULL>"]

print(f"{len(src_vocab)} mots source, {len(tgt_vocab)} mots cible (NULL compris).")
print(src_tok[0], "<->", tgt_tok[0])

# Résultats obtenu après correction :
# "2618 mots source, 2721 mots cible (NULL compris)."
```

```
2618 mots source, 2721 mots cible (NULL compris).
['דזשנע', 'ציין', 'זענען', 'בייגערנע', 'קראַטן', '.', 'היינטער', 'זיי', ',', 'אין', 'אַ', 'קרישטאַלענער', 'צעל', ',', 'דזשענע', 'געשמידטע', 'ווערטער', '.', 'געדענק', 'די', 'עצה', ',', '–']
['פון', 'אַן', 'עלטערן', ':', 'די', 'שולדיקע', ',', 'בעכער', 'פאַרסמטע', 'פערל', '–', 'זיי', 'לאָז', 'אַרויס', 'אויף', 'דער', 'פרוי', '.']
['ווי', 'אַ', 'דאַנק', 'פאַרן', 'געגאָד', ',', 'נעמען', 'אייביקייט', ';', 'נאָר', 'יענע', ',', 'די', 'בויען', 'דזשן', 'וועלן', ',', 'סאָלאָוויייַן', 'ווי', 'וואָס', 'טרילערן', 'פאַלש', 'זיי', 'בויען', 'דזשן', 'וועלן', ',', 'שאָנעווען', 'ניט', 'זאָלסטו', 'זיי', '–', 'קבר', 'אַ', 'איבער']
['מויל', 'דזשן', 'פון', 'אַרויס', 'זיי', 'לאָזסטו', 'קוים', '!', 'ווייל', 'תלין', 'זייער', 'וערן', ',', 'הענג', 'זיי', '.', 'שאָנעווען', 'ניט', 'זאָלסטו', 'זיי', '–', 'קבר', 'אַ', 'איבער']
['אמת', 'דעם', 'זאָג', 'איך', 'זוי', 'אַראָפּפאַלן', 'ניט', 'אַזוי', 'זאָלן', 'זעטערן', 'די', '.', 'שדים', 'זיי', 'וערן', '–', 'פון', 'דזשן', 'פון', 'ציי', '!', '–'] <-> ['–', 'tes',
'dents', 'sont', 'des', 'grilles', 'd’', 'os', '.', 'derrière', 'les', 'barreaux', ',', 'dans', 'une', 'geôle', 'de', 'cristal', ',', 'tes', 'mots', 'enchaînés',
'.', 'souviens-toi', 'du', 'conseil', 'd’', 'un', 'aîné', ':', 'les', 'mots', 'coupables', ',', 'qui', 'ont', 'versé', 'dans', 'ta', 'coupe', 'des', 'perles',
'empoisonnées', ',', 'laisse-les', 'sortir', 'en', 'liberté', '.', 'pour', 'te', 'remercier', 'de', 'ta', 'grâce', ',', 'ils', 'bâtiront', 'ton', 'éternité', '.',
'mais', 'les', 'autres', ',', 'les', 'innocents', ',', 'qui', 'chantent', 'faux', 'comme', 'des', 'rossignols', 'sur', 'une', 'tombe', ',', 'ne', 'les', épargne',
'pas', '.', 'mets-leur', 'la', 'corde', 'au', 'cou', ',', 'sois', 'leur', 'bourreau', '!', 'car', 'à', 'peine', 'échappés', 'de', 'ta', 'bouche', ',', 'ou', 'de',
'ta', 'plume', ',', 'ils', 'deviennent', 'des', 'démons', '.', 'que', 'les', 'étoiles', 'ne', 'viennent', 'à', 'tomber', 'du', 'ciel', ',', 'aussi', 'vrai', 'que',
'je', 'dis', 'vrai', '!']
```

```
# Vérification de la tokenisation (français)
tokenize("Souviens-toi du conseil d’un aîné : les mots, l’enfant... qu’il vienne !")
```

```
['souviens-toi',
 'du',
 'conseil',
 'd’',
 'un',
 'aîné',
 ':',
 'les',
 'mots',
 ',',
 'l’',
 'enfant',
 '…',
 'qu’',
 'il',
 'vienne',
 '!']
```

```
# Vérification de la tokenisation (yiddish)
tokenize("וויל איך, ליבער מענטש, וועל שוין לאַנג ניט ציען, וועל גיין באַגעגענען די צוויי מיידלעך... גיט אַ האַנט,")
```

```
['וויל',
 'איך',
 ',',
 'ליבער',
 'מענטש',
 ',',
 'וועל',
 'שוין',
 'לאַנג',
 'ניט',
 'ציען',
 ',',
 'וועל',
 'גיין',
 'באַגעגענען',
 'די',
 'צוויי',
 'מיידלעך',
 '…',
 'גיט',
 'אַ',
 'האַנט',
 ',']
```

Résultat obtenu (français) :

```
['souviens-toi', 'du', 'conseil', 'd’', 'un', 'aîné', ':', 'les', 'mots', ',', 'l’', 'enfant', '…', 'qu’', 'il', 'vienne', '!']
```

Résultat obtenu (yiddish) :

```
['וויל', 'איך', ',', 'ליבער', 'מענטש', ',', 'וועל', 'שוין', 'לאַנג', 'ניט', 'ציען', ',', 'וועל', 'גיין', 'באַגעגענען', 'די', 'צוויי', 'מיידלעך', '…', 'גיט', 'אַ', 'האַנט',
```

```
from collections import Counter

for nom, tok, vocab in [("yiddish", src_tok, src_vocab), ("français", tgt_tok, tgt_vocab)]:
    avec_ponct = [w for w in vocab if w[-1] in "…,;:!?»…)"]
    print(f"{nom} : {len(vocab)} mots distincts, dont {len(avec_ponct)} se terminent par de la ponctuation")
    print("   exemples :", avec_ponct[:8])
    print("   plus fréquents :", Counter(w for s in tok for w in s).most_common(10))
```

```
yiddish : 2618 mots distincts, dont 7 se terminent par de la ponctuation
   exemples : ['!', ',', '.', ':', ';', '?', '…']
   plus fréquents : [(',', 856), ('.', 602), ('512 ,אַ), ('310 ,די), ('294 ,אין), ('—', 292), ('259 ,און), ('229 ,פון), ('211 ,דער), ('155 ,זיך)]
français : 2721 mots distincts, dont 8 se terminent par de la ponctuation
   exemples : ['!', ',', '.', ':', ';', '?', '»', '…']
   plus fréquents : [(',', 932), ('.', 614), ('de', 495), ('la', 336), ('un', 273), ('le', 244), ('et', 221), ('à', 205), ('une', 191), ('les', 190)]
```

Résultats obtenus avant correction :

```
yiddish : 3390 mots distincts, dont 1184 se terminent par de la ponctuation
   exemples : ['!', '!..', '..', ':', ';', '?', '?..', 'אַדלער,']
   plus fréquents : [('541 ,אַ), ('320 ,די), ('—', 305), ('304 ,אין), ('267 ,און), ('240 ,פון), ('222 ,דער), ('160 ,האַט), ('156 ,מיט), ('154 ,זיך)]
français : 3626 mots distincts, dont 1268 se terminent par de la ponctuation
   exemples : ['!', '!…', ':', ';', '?', '?…', 'abattu,', 'abréger…']
   plus fréquents : [('de', 527), ('la', 351), ('le', 258), ('un', 239), ('et', 226), ('à', 206), ('les', 195), ('une', 166), ('dans', 163), ('en', 14
```

Résultats obtenus après correction :

```
yiddish : 2618 mots distincts, dont 7 se terminent par de la ponctuation
   exemples : ['!', ',', '.', ':', ';', '?', '…']
   plus fréquents : [(',', 856), ('.', 602), ('512 ,אַ), ('310 ,די), ('294 ,אין), ('—', 292), ('259 ,און), ('229 ,פון), ('211 ,דער), ('155 ,זיך)]
français : 2721 mots distincts, dont 8 se terminent par de la ponctuation
   exemples : ['!', ',', '.', ':', ';', '?', '»', '…']
   plus fréquents : [(',', 932), ('.', 614), ('de', 495), ('la', 336), ('un', 273), ('le', 244), ('et', 221), ('à', 205), ('une', 191), ('les', 190)]
```

4. IBM Model 1 : construire le modèle de traduction

On va y aller **une seule idée à la fois**. Toute la mécanique (les boucles, l’accumulation sur le corpus) est déjà écrite pour vous : vous allez compléter **une seule fonction**, qui répond à une question très concrète.

Pour un mot source f, et les mots cibles candidats d’une phrase (ex. : la, maison, NULL), comment répartir « 1 unité de certitude » entre ces candidats, sachant les $t(f \mid e)$ actuels ?

Un exemple numérique avant le code

Reprenons l'exemple de la Leçon 4. Phrase source : *das Haus*. Mots cibles candidats : *la*, *maison*. Avec t initialisé uniformément à $\frac{1}{3}$ partout :

$$\text{dénominateur} = t(\text{das} \mid \text{la}) + t(\text{das} \mid \text{maison}) = \tfrac{1}{3} + \tfrac{1}{3} = \tfrac{2}{3}$$

$$P(a = \text{la} \mid \text{das}) = \frac{t(\text{das} \mid \text{la})}{\text{dénominateur}} = \frac{1/3}{2/3} = 0{,}5 \qquad P(a = \text{maison} \mid \text{das}) = 0{,}5$$

C'est tout ce que votre fonction doit calculer : **une division**, répétée pour chaque candidat.

```
# Prends une paire de phrases : une phrase yiddish et sa traduction française
# Pour un mot yiddish f, on ne sait pas quel est le mot français correspondant.
# IBM Model 1 répartit une unité de certitude entre tous les mots français de la phrase
# plus un mot français e est susceptible de produire f, plus il reçoit de part

def posteriors_for_word(f, e_candidats, t):
    """
    f           : un mot source (ex. 'das')
    e_candidats : la liste des mots cible de la phrase, NULL compris (ex. ['<NULL>', 'la', 'maison'])
    t           : le dictionnaire courant des t(f|e)

    Retourne un dictionnaire {e: probabilité} qui doit sommer à 1.
    """
    denominateur = sum(t[(f, e)] for e in e_candidats)  # <- fourni, c'est la somme du bas de la formule

    probas = {}
    for e in e_candidats:
        probas[e] = t[(f, e)] / denominateur

    return probas
```

```
# Testez votre fonction ici avant de continuer : avec t uniforme, vous devez obtenir 0,5 / 0,5.
t_test = defaultdict(lambda: 1.0 / 3)
resultat = posteriors_for_word("das", ["la", "maison"], t_test)
print(resultat)
assert abs(sum(resultat.values()) - 1.0) < 1e-6, "Les probabilités doivent sommer à 1."
assert abs(resultat["la"] - 0.5) < 1e-6, "Avec t uniforme, on doit retrouver 0,5 / 0,5."
print("Test réussi !")
```

```
{'la': 0.5, 'maison': 0.5}
Test réussi !
```

Si le test passe, vous avez fini la partie difficile. Le reste — répéter ce calcul sur tout le corpus, puis ré-estimer $t(f \mid e)$ — est entièrement fourni ci-dessous ; lisez-le, il ne fait qu'appeler la fonction que vous venez d'écrire.

```
def e_step(src_tok, tgt_tok, t):
    """Parcourt tout le corpus et accumule les comptes fractionnaires, en
    appelant posteriors_for_word() pour chaque mot source rencontré."""
    count = defaultdict(float)
    total_e = defaultdict(float)
    for f_sent, e_sent_raw in zip(src_tok, tgt_tok):
        e_sent = ["<NULL>"] + e_sent_raw
        for f in f_sent:
            probas = posteriors_for_word(f, e_sent, t)
            for e, p in probas.items():
                count[(f, e)] += p
                total_e[e] += p
    return count, total_e

def m_step(count, total_e):
    """Ré-estime t(f|e) = compte(f,e) / total(e). Une paire jamais vue ensemble reste à 0."""
    new_t = defaultdict(float)
    for (f, e), c in count.items():
        new_t[(f, e)] = c / total_e[e]
    return new_t
```

5. Entraînement : faites tourner EM (Expectation-Optimisation)

```
# Initialisation : t(f|e) uniforme sur tout le vocabulaire source, pour un vrai entraînement
t = defaultdict(lambda: 1.0 / len(src_vocab))

N_ITER = 10
for it in range(N_ITER):
    count, total_e = e_step(src_tok, tgt_tok, t)
    t = m_step(count, total_e)

# petit test de cohérence : la somme des t(f|e) sur f, pour un e fixé, doit faire ~1
s = sum(t[(f, tgt_vocab[0])] for f in src_vocab)
print(f"Somme de contrôle pour e={tgt_vocab[0]!r} (doit être proche de 1) : {s:.3f}")
```

```
Somme de contrôle pour e='!' (doit être proche de 1) : 1.000
```

6. Sous-produit utile : extraire un lexique bilingue

Pour chaque mot cible, quel mot source lui est le plus probablement associé ? C'est exactement ce que font les dictionnaires bilingues construits automatiquement pour les langues peu dotées.

```
def top_translation(e, k=3):
    scores = [(t[(f, e)], f) for f in src_vocab]
    scores.sort(reverse=True)
    return scores[:k]

for e in tgt_vocab:
    if e == "<NULL>":
        continue
    best = top_translation(e)
    print(f"{e:12s} -> " + ", ".join(f"{f} ({p:.2f})" for p, f in best))
```

```
!            -> ! (0.92), – (0.08), , (0.00)
&            -> (0.14) והאחים ,(0.14) פּאַרטרייטער ,(0.14) ראָם
,            -> , (0.77), (0.04) . ,(0.05) אַ
.            -> . (0.81), (0.04) , ,(0.05) אַ
```

```
1953         -> 1954 (0.48), 1953 (0.48), – (0.03)
1954         -> 1954 (0.48), 1953 (0.48), – (0.03)
:            -> : (0.99), (0.00) ,דער (0.00) ,און
;            -> ; (0.68), (0.03) ,איר (0.08) ,האָט
?            -> ? (0.99), (0.01) – ,(0.01) ,איז
a            -> (0.02) ,דער (0.03) . ,(0.89) ,האָט
a-t-elle     -> (0.15) ,מירעלען (0.15) ,ס'קינד (0.15) ,קלערן
a-t-il       -> (0.08) ,קלויז (0.08) ,שריפה (0.17) ,קומט
abandon      -> (0.03) ,דער (0.07) ,שטאָט (0.34) ,אויף
abandonnes   -> (0.06) ,וועסט (0.06) ,זשׁ-געזונט (0.06) ,צום־ווידערזען
abattu       -> (0.15) ,צעשמעלצן (0.15) ,קוואָלן (0.15) ,שוואַרץ
abeille      -> (0.02) ,וויילדע (0.07) ,איז (0.87) ,בין
abeilles     -> (0.07) – ,(0.20) ,פינגער (0.64) ,בינען
abord        -> (0.00) – ,(0.46) ,צו (0.53) ,ערשט
abîme        -> (0.04) ,אויף (0.28) ,אָן (0.51) ,אָפגרונט
acacias      -> (0.14) ,צוווּגן (0.14) ,קוועלקלט (0.14) ,קליאָן
accompagne   -> (0.31) ,באַגלייט (0.31) ,וואָקסענער (0.31) ,לעצטער
accompagner  -> (0.17) ,איסער (0.17) ,אָוועק (0.17) ,טויבנשלאָק
accompagné   -> (0.15) ,וואַרעם (0.15) ,לענדער (0.15) ,צוּטן
accord       -> (0.12) ,זאָגן (0.12) ,מסכים (0.12) ,רגע
acharne      -> (0.02) ,שׁטערדיקע (0.06) ,פּיצער (0.06) ,טויבן
achetée      -> (0.03) ,פענדזלען (0.03) ,צענדליק (0.03) ,שיינקייט
acier        -> (0.03) ,פליט (0.19) ,קרבן (0.62) ,שטאָלענע
adieu        -> (0.04) ,מיטגעפלויגן (0.04) ,שיינעם (0.41) ,איידער
adjuré       -> (0.07) ,עולם-הזה (0.07) ,פאַרשווויירן (0.07) ,ראַטעווען
admirer      -> (0.03) ,פענדזלען (0.03) ,צענדליק (0.03) ,שיינקייט
affaler      -> (0.04) ,פאַרקניפט (0.04) ,פאַרשיכורטע (0.04) ,שוואַרצאַפלשפראַך
affamé       -> (0.07) ,סקעלעטן (0.07) ,פלאַטשיקן (0.07) ,שטערן
affleure     -> (0.09) ,פרישקייט (0.09) ,קאָפּען (0.09) ,ראָזע
affût        -> (0.17) ,זאָל (0.17) ,פלאָקערן (0.17) ,טרוקענעם
agenouillée  -> (0.10) ,אָדלערס (0.12) ,מיטן (0.15) ,צוזאַמען
agneau       -> (0.14) ,אין (0.18) ,בלאָ (0.23) ,שעפּסלע
agonie       -> (0.06) ,נאָענטע (0.06) ,קאָרטשעט (0.06) ,רודניצקער
agrafe       -> (0.03) ,פענדזלען (0.03) ,צענדליק (0.03) ,שיינקייט
ah           -> (0.06) ,זמרל (0.06) ,פאַרבענקט (0.06) ,קאַנאַל
ai           -> (0.08) ,כ'האָב (0.12) ,איך (0.70) ,האָב
[… 2680 lignes omises dans cette version PDF …]
```

Question : certains mots cible pointent-ils de façon convaincante vers NULL (aucun mot source ne leur correspond vraiment) ? Que représentent ces cas concrètement ?

7. Modèle de langue (fourni)

Un bigramme avec lissage de Laplace, entraîné sur le **monolingue cible** uniquement — exactement l'esprit du canal bruité : $P(e)$ ne nécessite aucune donnée parallèle.

```python
class BigramLM:
    def __init__(self, sentences):
        self.unigrams = Counter()
        self.bigrams = Counter()
        self.vocab = set()
        for s in sentences:
            toks = ["<s>"] + tokenize(s) + ["</s>"]
            self.vocab.update(toks)
            for w in toks:
                self.unigrams[w] += 1
            for w1, w2 in zip(toks, toks[1:]):
                self.bigrams[(w1, w2)] += 1
        self.V = len(self.vocab)

    def logprob(self, sentence_tokens):
        toks = ["<s>"] + sentence_tokens + ["</s>"]
        lp = 0.0
        for w1, w2 in zip(toks, toks[1:]):
            num = self.bigrams[(w1, w2)] + 1
            den = self.unigrams[w1] + self.V
            lp += math.log(num / den)
        return lp

lm = BigramLM(tgt_sents)
print("logP('le chat dort') =", lm.logprob(tokenize("le chat dort")))
```

```
logP('le chat dort') = -29.162057662882194
```

8. Le décodeur : combiner $P(f \mid e)$ et $P(e)$

On simplifie radicalement la recherche ($\arg\max_e$ sur **toutes** les phrases possibles est impraticable à la main) : pour chaque mot source, on ne garde que ses k meilleures traductions candidates, on génère des combinaisons, et on les score. Toute la mécanique de recherche est fournie — vous n'écrivez que **le score d'une seule combinaison**, qui est une simple addition.

```python
import itertools, random

def candidate_words(f, k=3):
    """Les k meilleures traductions candidates d'un mot source, d'après t(f|e). Fourni."""
    scores = [(t[(f, e)], e) for e in tgt_vocab if e != "<NULL>"]
    scores.sort(reverse=True)
    return [e for _, e in scores[:k]]

def decode_greedy(f_sent_tokens):
    """Traduction mot-à-mot gloutonne : pour chaque mot source, prend sa meilleure traduction. Fourni."""
    return " ".join(candidate_words(f, k=1)[0] for f in f_sent_tokens)
```

À vous : noter une combinaison candidate

Pour une phrase source $(f_1, \ldots, f_m)$ et une combinaison candidate $(e_1, \ldots, e_m)$ (une traduction candidate pour chaque mot, dans l'ordre), le score du canal bruité est :

$$\text{score} = \underbrace{\sum_{j=1}^{m} \log t(f_j \mid e_j)}_{\text{modèle de traduction}} + \underbrace{\log P(e_1, \ldots, e_m)}_{\text{modèle de langue}}$$

Le second terme, c'est exactement `lm.logprob(...)` de la section 7.

```
def score_combo(f_sent_tokens, combo):
    """
    f_sent_tokens : les mots source, ex. ['die', 'katze', 'läuft']
    combo         : une combinaison candidate de mots cible, même longueur, ex. ('le', 'chat', 'court')

    Retourne le score du canal bruité (un seul nombre, plus il est grand, mieux c'est).
    """
    score_traduction = sum(math.log(t[(f, e)] + 1e-12) for f, e in zip(f_sent_tokens, combo))
    # Indice : zip(f_sent_tokens, combo) donne les paires (f_j, e_j) dans l'ordre.
    # Indice 2 : utilisez math.log(t[(f, e)] + 1e-12) -- le +1e-12 évite log(0).

    score_langue = lm.logprob(list(combo))  # <- fourni

    return score_traduction + score_langue
```

Le reste — générer les combinaisons candidates et garder la meilleure — est fourni : il ne fait qu'appeler `score_combo()` autant de fois que nécessaire.

```
def decode_noisy_channel(f_sent_tokens, k=3, n_samples=200):
    """Génère des combinaisons candidates (produit cartésien si petit, sinon tirage aléatoire),
    et renvoie celle qui maximise score_combo(). Fourni."""
    cand_lists = [candidate_words(f, k=k) for f in f_sent_tokens]

    total_combos = 1
    for c in cand_lists:
        total_combos *= len(c)

    if total_combos <= n_samples:
        combos = itertools.product(*cand_lists)
    else:
        combos = (tuple(random.choice(c) for c in cand_lists) for _ in range(n_samples))

    best_score, best_combo = -1e18, None
    for combo in combos:
        s = score_combo(f_sent_tokens, combo)
        if s > best_score:
            best_score, best_combo = s, combo

    return " ".join(best_combo) if best_combo else ""

test_sent = tokenize("die Katze läuft")
print("Mot-à-mot :", decode_greedy(test_sent))
print("Canal bruité :", decode_noisy_channel(test_sent))
```

```
Mot-à-mot : … … …
Canal bruité : … ” …
```

Question : sur quels types de phrases le décodeur « canal bruité » fait-il mieux que le simple mot-à-mot ? Sur quels types ne fait-il pas mieux — et pourquoi, d'après ce que vous savez des limites de Model 1 ?

9. Traduire un jeu de test

```
# Séparez quelques phrases de test (idéalement non vues à l'entraînement, sur votre vrai corpus).
#test_src = src_sents[-3:]
#test_ref = tgt_sents[-3:]

system_hyps = [decode_noisy_channel(tokenize(s)) or decode_greedy(tokenize(s)) for s in test_src]

for s, h, r in zip(test_src, system_hyps, test_ref):
    print(f"SRC: {s}\nHYP: {h}\nREF: {r}\n")
```

```
SRC: געפונען, געפונען! אָט איז דער חלום פון מײַן חלום – –
HYP: pourtant , pourtant ! vois est cet rêve noir mon rêve – colonnes
REF: Trouvé, je l'ai trouvé ! Le voici, le rêve de mon rêve…

SRC: כ'האָב גאָרנישט געפרעגט, נאָר דערלאַנגט אַן אָקרײַען ברויט, בײַ די ראַנדן פאַרשימלט.
HYP: pensais “ ” , mais sauvages métamorphosée ” moisi , poète les bordée ” .
REF: Sans rien demander, je lui tends un quignon de pain, moisi sur les bords.

SRC: – מײַן נאָמען איז פעליציע פּאָזנאַנסקי. דער שרײַבער י. זינגער האָט מיך פאַראייביקט אין אַ ראָמאַן. אָמאָל האָב איך אויסגעזען אַנדערש. נאָר דאָס איז ניט וויכטיק.
HYP: – ma nom est œuvre poznanski bonjour éclair écrivain allé bonjour allé . “ eut avais … rouge humaine … . demi-siècle pensais j' ressemblait béante . mais mousse est pas … .
REF: – Mon nom est Félicia Poznanski. L'écrivain Israël Joshua Singer m'a immortalisée dans un roman. Autrefois j'avais fière allure. Mais là n'est pas l'important.

SRC: דער זונפאַרגאַנג באַלײַכט אירע קנייטשן מיטן ליכט פון גרינע גלײַווערעס. זי ווערט דינער, אײנגעשרומפּענער און זעט אויס ווי אַ מומיע פון אַן אַלט-עגיפּטישער פּרינצעסין
HYP: éclair couchant brille toutes rides nuée flamme sombre disparaître ” . elle sciure tailladés sans “ et voit chemise comme une ” du attendant “ “
REF: Le soleil couchant illumine ses rides d'une verte lueur de luciole. Elle se ratatine, plus fine, plus menue, l'air d'une antique momie de princesse égyptienne.

SRC: – מען דאַרף ניט קיין ווַאַסער, מען דאַרף ניט. אַ צוויק אונטערן האַרצן, אַ נאַרישקייט. וווּ האָלטן מיר ? יאָ, כ'וועל מאַכן בקיצור –
HYP: – passage sept ne jamais eau , passage enterrer ne . un “ avance sons tu humaine … heures où … nous tu perçoivent , veiller ” … colonnes
REF: – Inutile de chercher de l'eau, inutile. Un pincement au cœur, ce n'est rien. Où en étions-nous ? Ah oui, je vais abréger…

SRC: אָן אפשר איז גאָר שולדיק זײַן פאַליטרע, האָ ?
HYP: et maternelle est … “ son palette sans hein ?
REF: Et si la coupable était sa palette ?

SRC: זײַנע ווַאַסערדיקע אויגן ווערן אויסגעפוקלט מער. גיסן זיך איבער אויף דער פּאַליטרע. אַ נאַסע פלעמלדיקע ראָזקייט באַדעקט זײַן פנים.
HYP: ait exorbités transmuée dis exorbités tombeau . ” seuls au-dessus papier étoile palette . une ” … rose déversées son visage .
REF: Ses yeux aqueux s'exorbitent plus encore. Débordent, se déversent sur la palette. Une humide roseur de flamme vacillante inonde son visage.

SRC: – אַי, צאַלקע, זײַן אייפערזיכטיק אין אַ קוימען... גוט, כ'וועל דיר זאָגן, ס'איז געווען –
HYP: – ” , tsalke tu laisser “ dans une cheminée cordes épancher tu marécage trancher résidait , enfui phosphorescente – colonnes –
REF: – Voyons, Tsalke, brûler de jalousie dans une cheminée… Bon, je vais te le dire, c'était…

SRC: ס'נעמט וואַלקענען, רעגענען, מיט וואַרעמע באַבישע טערערן. זיי, די טערערן, פאַרלעשן דעם שוטער, פילן אַן די קאַנאַוווע.
HYP: … ” , … sans près somnambules ” piquent . jeunes , les larmes , … approche éclaire tu ondoyantes donne les orties .
REF: Le ciel se couvre de nuages, se met à pleuvoir, de chaudes larmes de grand-mère. Elles, ces larmes, éteignent le bûcher, inondent la fosse.

SRC: קיינער באַפעלט ניט מע זאָל אויפשטיין. די ליפן, ווי אָפּגעהאַקטע פינגער, קאָנען זיך ניט באַוועגן...
HYP: personne ” ne ma-man heure “ . les lèvres , telles ” doigt tu savent seuls pas poussée …
REF: Personne ne donne l'ordre de se lever. Nos lèvres gelées, tels des doigts coupés, ne peuvent remuer…
```

```
SRC: ס'האָט זיך דערהערט אַ שטעפערײַ פֿון אַ קוילנזאַרפֿער, וואָס האָט אויפגעהויבן פון זומפ אַ וואַרצל ווי אַ נאָז פון אַ העלפֿאַנד.
HYP: fer seuls entendu un … suspendu un “ tu eaux a ramassé du dresse une ” comme un nez noir une … .
REF: Soudain a retenti un crépitement de mitrailleuse, soulevant du marais une racine comme une trompe d’éléphant.

SRC: אויף מאָרגן, אין דולער בלאָנדזשענישׂ, האָב איך ענדלעך דערטאַפּט דאָס בערגל. נאָר פון מיידל איז דאָרט פאַרבליבן נאָך ווינציקער ווי פון אַ חלום.
HYP: tord senti sans verre ” ” , ami j’ pourtant … mousse dois . mais du fille est “ derniers après ” telles sombre humaine rêve .
REF: Le matin, en une folle errance, j’ai enfin retrouvé la butte. Mais de la fille il ne restait rien, moins encore que d’un rêve.

SRC: בײַם ווערן אַ פּעלצל ביסטו פאַרבליבן אַ שעפּעלע.
HYP: chats dis une papiers es-tu parmi humaine errant .
REF: Devenu petit manteau de peau, tu es resté petit agneau.

SRC: אַ בּיסט בין איך געווען אין דזשינע פּליגל. פון זיך אַליין פאַרשוווּנדן. זיבן שטראַליקע טויבן האָבן מיך געבראַכט אַהיים.
HYP: un “ abeille je époux verre tes ailes bonjour du ans lui-même disparu . six “ voraces pupilles mansarde ” … .
REF: J’étais un pur esprit entre tes ailes. Transporté hors de moi. Sept colombes nimbées de rayons m’ont ramené à la maison.

SRC: וווען כ'בין געווארן פאַר דיר צו גרויס, האָסטו מיר אָפּגענעבן דזשינע הענט — די צוויי אַרבל, צו פאַרלענגערן די פרייַנדשאַפֿט.
HYP: enfuie suis devenu haine toi abord taire tu jour-là obscure … tes mains colonnes les deux essuie , vers … vieille “ .
REF: Quand je suis devenu trop grand pour toi, tu m’as sacrifié tes bras — les deux manches, pour rallonger notre amitié.

SRC: צו זשינע אויערן דערטראָגט זיך אַ ממזר, אַ גרויליק בענקענדיקער מממזר, אַ דונער מיט אָפּגעהאַקטע פליגל...
HYP: vers moisissure … … s’ un “ , une … ” ” , une ” avec ” blanche …
REF: À ses oreilles parvient un long meuh, un terrifiant, un languissant mugissement, tonnerre aux ailes coupées…

SRC: — אַ גאָלדענער שלייער — אַזאַ בוים דערקענט מען בײַ נאַכט. אָדער אים, זעסט, ברודערקע, ניין.
HYP: — non , frérot , telle arbre sais-tu passage poète nuit . milieu force , est-il , — un “ … .
REF: — Non, frérot, un tel arbre on le repère la nuit. Autour de lui, tu vois — un voile d’or !

SRC: — זעצט יאָאכים די האַק אין בוים אָדער טרוקן, — סטאָדע אָפּקסן, זאָל פּערד, — ער וועט קלעקן אָפּצוברעכן.
HYP: — sauver protégera ” ” une … veulent tu “ telles ” , colonnes froisser joachim ces hache dans arbre bout .
REF: — Il y en aura assez pour rôtir tout un troupeau de bœufs, sec comme la poix !

SRC: אַ גראָע צעכוואַליעטע וואַנט, ווי אין דער וואַנט וואָלטן זיך בעטרונקען וועלף, שווימט אַרויס הינטער די זשלן פון רעגן.
HYP: une déployées … mur , comme dans cet glisse reconstruire s’ … … sans vogue jaillit derrière les gamins noir funérailles .
REF: Un mur gris comme une mer démontée, comme si en ce mur s’était noyée une horde de loups, émerge derrière les colonnes de pluie.

SRC: — אורשוליאַ, וויפל איז דער זייגער ?
HYP: — ursula , porté est étoile pouvais-je ?
REF: — Ursula, quelle heure est-il ?

SRC: דער רעגן טוט אַ זעץ אין שויב מיט זשינע בלײַענע פויסטן.
HYP: éclair pluie reste un coup rouge carreau près moisissure plomb “ .
REF: La pluie cogne au carreau de ses poings de plomb.

SRC: זינט איך האָב געפונען דעם יינגל אויפן דעמב, איז ער געוואָרן מײַן שוואַרצאַפּל.
HYP: souvienne j’ ai gravée calciné garçon cour chêne tu est il devenue petits … .
REF: Du jour où j’ai trouvé ce garçon sur le chêne, il est devenu la prunelle de mes yeux.

SRC: און דער מענטש האָט אַרײַנגענעקוקט אינעווייניק און נאָרנישט ניט געזען, וואָל זײַן פּנים איז באַקלעפּט געווארן פון שפּינוועבס בײַם בייגן זיך איבערן מויל פון ברונעם.
HYP: et cet homme avait “ intérieur vieux ” n’ vu , car mettre visage coffret ” devenu sombre ” chats réveille seuls met épargne du tatares .
REF: L’homme a plongé le regard à l’intérieur et n’a rien vu car son visage s’est englué de toiles d’araignées quand il s’est penché sur la bouche du puits.

SRC: און דעמאָלט האָט ער פון בוזעם אויסגעפלאָנטערט אַ שטריק, זי פאַרקניפּט אַרום אַ האָק, און ווי אַ קוימענקערער אין אַ קוימען זיך אַרונטערגעלאָזן אין ברונעם.
HYP: propre aile eut il du sein “ humaine corde tu elle traînés autour humaine ” , et tels une … rouge un cheminée ans ” verre puits .
REF: Alors il a tiré de son sein une corde, l’a nouée autour d’un crochet, et comme un ramoneur dans une cheminée s’est coulé au fond du puits.

SRC: ערשט דאָרטן, מיט אַ קלאַפּנדיק האַרץ, און מיט אויגן ווי ווילדע מאָנבלומען, האָט ער אין ביידע הענט אַרײַנגענומען דעם אוצר און עס געהאַלטן אַנטקעגן.
HYP: bonhomme marécage , près un … cœur , et près yeux tels crevé pavots sans a sauver rouge petites-filles baisent tcharnohouz approche … vieux demeure traitait face .
REF: Là enfin, le cœur battant, les yeux comme des pavots sauvages, il a pris à deux mains le trésor et l’a tenu face à lui.

SRC: : און ער האָט נאָך אַ מאָל אין בייַדע הענט אַרײַנגענומען דעם שאָרבן און ווי אַ הונט אַ צעשלאָגענער דערלאַנגט אַ וואַיע
HYP: et il a encore un peins dans côtés mains tcharnohouz approche crâne vieux tels une protestait-il une ” dressé humaine … :
REF: Il a pris de nouveau le crâne à deux mains et tel un chien battu a poussé un hurlement :

SRC: .און ער האָט דערפילט, אַז דער קאָפּ, וואָס ער טראָגט שוין אַזוי פיל יאָרן אויף די אַקסלען, איז ניט זשינער
HYP: et sauver eut ressenti tu rien étoile tête , bas sauver voûtée pommes cela pourquoi années tord les épaules , est pas “ .
REF: Et il a senti que la tête qu’il portait sur les épaules depuis tant d’années n’était pas la sienne.

SRC: דער מלאך מיט די פּאַרסאַזשעטע פליגל טראָגט אַוועק דאָס געסל — דעם שוואַרצן אָרן.
HYP: cet ange aux les disparaît blanche blancs volée mousse ruelle — calciné tranché vivantes .
REF: L’ange aux ailes noircies de suie emporte la ruelle — le noir cercueil.

SRC: — דיר גלוסט זיך איבערשנײַדן, האַ ?
HYP: — trancher trancher seuls trancher tu hein ?
REF: — Tu as envie de trancher, hein ?

SRC: .אַצינד זעט ער די לבנה מיט זײַן גלעזערן אויג. אויף דעם אַנדערן העכנט אַ שלאָס. דער זילבערנער שליסל איז ניט מער אויף דער וועלט
HYP: sent voit venait vieille lune près mettre rayon œil . papier approche par-dessus pend un ” . éclair ” ” est pas profond tord éclair monde .
REF: À cette heure, il voit la lune de son œil de verre. L’autre œil est sous serrure. La clé d’argent n’est plus de ce monde.
```

10. Évaluation — votre système vs. l’état de l’art

On compare trois traducteurs sur le **même jeu de test** : votre IBM Model 1 + canal bruité, une traduction mot-à-mot (baseline minimale), et un modèle moderne (NLLB-200 ou un LLM via prompt).

```
import sacrebleu

baseline_hyps = [decode_greedy(tokenize(s)) for s in test_src]

def show_bleu(name, hyps, refs):
    bleu = sacrebleu.corpus_bleu(hyps, [refs])
    print(f"{name:25s} sacreBLEU = {bleu.score:.1f}")
    return bleu.score

show_bleu("Mot-à-mot (baseline)", baseline_hyps, test_ref)
show_bleu("IBM Model 1 + canal bruité", system_hyps, test_ref)
```

```
Mot-à-mot (baseline)      sacreBLEU = 2.8
IBM Model 1 + canal bruité sacreBLEU = 1.3
```

```
1.2793187991824777
```

Comparaison avec un système moderne (fourni)

Adaptez le code de langue NLLB à votre paire de langues (voir la liste des codes FLORES-200). Si votre langue n’est pas couverte, essayez un LLM via prompt (section suivante) à la place.

Nous essayons ci-dessous **Transformers** puis **Torch**, deux décodages différents du même modèle `NLLB-200-distilled-600M` (appelé avec les mêmes poids). Transformers appelle le modèle via une recherche en faisceau à 4 hypothèses (`num_beams=4`), tandis que Torch l'appelle directement par défaut.

```
# TRANSFORMERS
try:
    from transformers import pipeline
    # Codes de langue NLLB adaptés à notre paire : yiddish ("ydd_Hebr") -> français ("fra_Latn")
    translator = pipeline("translation", model="facebook/nllb-200-distilled-600M",
                          src_lang="ydd_Hebr", tgt_lang="fra_Latn")
    nllb_hyps = [translator(s)[0]["translation_text"] for s in test_src]
    hyps_nllb_transformers = nllb_hyps  # gardé pour COMET (nllb_hyps est réécrit par la cellule Torch)
    for s, h in zip(test_src, nllb_hyps):
        print(f"SRC: {s}\nNLLB: {h}\n")
    show_bleu("NLLB-200 (600M)", nllb_hyps, test_ref)
except Exception as e:
    print("NLLB indisponible pour cette paire de langues :", e)
    print("-> utilisez un LLM via prompt (cellule suivante) comme point de comparaison.")

# Score obtenu :
# NLLB-200 (600M)           sacreBLEU = 13.4
```

```
SRC: — — געפונען, געפונען! אָט איז דער חלום פון מײַן חלום
NLLB: Trouvez, trouvez ! Voilà le rêve de mon rêve

SRC: כ'האָב גאָרנישט געפרעגט, נאָר דערלאָנגט אַן אָקרײַען ברויט, בײַ די ראַנדן פאַרשימלט.
NLLB: Je n'ai rien demandé, mais j'ai offert un pain d'ocre, à la randonnée.

SRC: — מײַן נאָמען איז פעליציע פּאָזנאַנסקי. דער שרײַבער י. י. זינגער האָט מיך פֿאַראײביקט אין אַ ראָמאַן. אָמאָל האָב איך אויסגעזען אַנדערש. נאָר דאָס איז ניט וויכטיק.
NLLB: Je m'appelle Félicie Poznansky. L'écrivain Y. E. Singer m'a conçu dans un roman. J'avais l'air différent une fois. Mais ce n'est pas important.

SRC: דער זונפאַרגאַנג באַלײַכט אירע קנייטשן מיטן ליכט פון גרינע גלייוועקס. זי ווערט דינער, אײַנגעשרומפּענער און זעט אויס ווי אַ מומיע פון אַן אַלט-עגיפּטישער פרינצעסין
NLLB: Le coucher du soleil éclaire ses filles avec la lumière de glaives vertes. Elle devient plus servante, plus éblouissante et ressemble à une momie d'une princesse égyptienne ancienne

SRC: — מען דאַרף ניט קיין וואַסער, מען דאַרף ניט. אַ צוויק אונטערן האַרצן, אַ נאָרישקייט. ווו האַלטן מיר ? יאָ, כ'וועל מאַכן בקיצור —
NLLB: Il n'y a pas besoin d'eau, il n'y a pas besoin. Un excès sous le cœur, une folie.

SRC: ? און אפשר איז גאָר שולדיק זײַן פאַליטרע, האָ
NLLB: Et peut-être que c'est sa peinture qui est vraiment coupable, hein ?

SRC: זײַנע וואַסערדיקע אויגן ווערן אויסגעפוקלט מער. גיסן זיך איבער אויף דער פּאַליטרע. אַ נאַסע פלעמלדיקע ראָזקייט באַדעקט זײַן פּנים.
NLLB: Ses yeux aquatiques s'ouvrent de plus en plus. Ils se jettent sur la palette. Une rosée flamboyante humide couvre son visage.

SRC: — — אַי, צאַלקע, זײַן אייפערזיכטיק אין אַ קוימען... גוט, כ'וועל דיר זאָגן, ס'איז געווען —
NLLB: Ah, bonheur, être éphémère dans un coin... Bon, je vais vous dire, c'était...

SRC: ס'נעמט וואָלקנען, רעגענען, מיט וואַרעמע באַבישע טערען. זיי, די טערען, פאַרלעשן דעם שטער, פילן אָן די קאָנאָוווע.
NLLB: Il pleut, il pleut, avec les larmes chaleureuses de Bobbie. Elles, les larmes, oublient la nuée, se sentent sans la toile.

SRC: ...קיינער באַפעלט ניט מע זאָל אויפשטיין. די ליפּן, ווי אָפּגעהאַקטע פינגער, קאָנען זיך ניט באַוועגן
NLLB: Personne ne commande de se lever. Les lèvres, comme des doigts coupés, ne peuvent pas bouger...

SRC: ס'האָט זיך דערהערט אָ שטעפּערס פֿון אַ קוילנזאַרפֿער, וואָס האָט אויפגעהויבן פון זומפ אָ וואַרצל ווי אָ נאָז פון אַ העלפאַנט.
NLLB: On entendit une clameur d'un conservateur qui relevait d'une soupe une racine comme un nez d'un serpent.

SRC: אויף מאָרגן, אין דוּלער בלאָנדזשענישׂ, האָב איך ענדלעך דערטאַפּט דאָס בערגל. נאָר פון מיידל איז דאָרט פאַרבליבן נאָך ווינציקער ווי פון אַ חלום.
NLLB: Le lendemain matin, dans une blonde douce, j'ai finalement atteint la montagne. Seule une jeune fille y est restée pendant vingt ans, comme si c'était un rêve.

SRC: בײַם ווערן אַ פּעלצל ביסטו פאַרבליבן אַ שפּעלצל.
NLLB: En devenant une pellicule, vous restez une pellicule.

SRC: אַ בּיסט בין איך געווען אין דײַנע פּליגל. פון זיך אַליין פאַרשוווּנדן. זיבן שטראַליקע טויבן האָבן מיך געבראַכט אַהיים.
NLLB: J'étais un hôte dans tes ailes. Je me suis évanoui par moi-même. Sept étoiles brillantes m'ont ramené à la maison.

SRC: ווען כ'בין געוואָרן פאַר דיר צו גרויס, האָסטו מיר אָפּגענעבן דײַנע הענט — די צוויי אַרבל, צו פאַרלענגערן די פרײַנדשאַפט.
NLLB: Quand je suis devenu trop grand pour toi, tu m'as donné les deux mains pour prolonger l'amitié.

SRC: ...צו זײַנע אויערן דערטראָגט זיך אַ מממו, אַ גרויליק בענקענדיקער מממו, אַ דונער מיט אָפּגעהאַקטע פליגל
NLLB: À ses oreilles se présente une mamme, une mamme grossière, une donnée aux ailes démembrées...

SRC: — אַ גאָלדענער שליימער — ניין, ברודערקע, אַזאַ בוים דערקענט מען בײַ נאַכט. אַרום אים, זעסט, — זענען אימס.
NLLB: Non, ma sœur, on reconnaît un tel arbre pendant la nuit. Il est entouré d'une couche d'or.

SRC: — ער וועט קלעקן אָפּצובראָטן אַ סטאַדע אָקסן, טרוקן ווי פּערד, — זעצט יאָאַכים די האַק אין בוים אַרײַן.
NLLB:  Il écrasera une stade d'oiseaux, secs comme la paille,  Joachim ramasse la hache dans l'arbre.

SRC: אַ גראָע צעכוואָליעטע וואַנט, ווי אין דער וואַנט וואָלטן זיך געטרונקען וועלף, שווימט אַרויס הינטער די זײַלן פון רעגן.
NLLB: Un mur gris et déchiré, comme dans le mur, plonge à l'extérieur derrière les branches de la pluie.

SRC: — אורשוליאַ, וויפל איז דער זייגער ?
NLLB:  Ursula, quelle est l'heure ?

SRC: דער רעגן טוט אַ זעץ אין שויב מיט זײַנע בלײַענע פויסטן.
NLLB: La pluie fait une sieste dans la poussière avec ses plumes blanches.

SRC: זינט איך האָב געפונען דעם יינגל אויפן דעמב, איז ער געוואָרן מײַן שוואַרצאַפּל.
NLLB: Depuis que j'ai trouvé le garçon, il est devenu mon chapeau.

SRC: און דער מענטש האָט אַרײַנגעקוקט אינעווייניק און נאָרנישט ניט געזען, ווײַל זײַן פּנים איז באַקלעפט געוואָרן פון שפּינוועבס בײַם בייגן זיך איבערן מויל פון ברוגעס.
NLLB: L'homme entre dans la maison, il regarde et il ne voit rien. Il a les yeux pleins d'or et il est plein de tristesse.

SRC: און דעמאָלט האָט ער פון בוזעם אויסגעפלאָנטערט אַ שטריק, זי פאַרקניפּט אָרום אַ האָק, און ווי אַ קוימענקרערער אין אַ קוימען זיך אַרונטערגעלאָזן אין ברוגעס.
NLLB: Et puis il a planté un plan de bosse, elle s'est enroulée autour d'un crochet, et comme un marchand dans un couloir se tourne autour dans le brun.

SRC: ערשט דאָרטן, מיט אַ קלאַפּנדיק האַרץ, און מיט אויגן ווי ווילדע מאָנבלומען, האָט ער אין ביידע הענט אַרײַנגענומען דעם אוצר און עס געהאַלטן אַנטקעגן.
NLLB: D'abord là, avec un cœur battant, et des yeux comme des colliers sauvages, il prit dans ses deux mains le trésor et le déposa.

SRC: און ער האָט נאָך אַ מאָל אין בייַדע הענט אַרײַנגענומען דעם שאָרבן און ווי אַ הונט אַ צעשלאָגענער דערלאָנגט אַ וואָיע :
NLLB: Jsus prend encore une fois le morceau de pain dans ses deux mains. Un chien qui croit que le chien est mu et il part en criant:

SRC: און ער האָט דערפילט, אַז דער קאָפּ, וואָס ער טראָגט שוין אַזוי פיל יאָרן אויף די אַקסלען, איז ניט זײַנער.
NLLB: Il s'est rendu compte que la tête qu'il portait depuis tant d'années n'était pas la sienne.

SRC: דער מלאך מיט די פּאַרסאָזשעטע פליגל טראָגט אַוועק דאָס געסל — דעם שוואַרצן אַרון.
NLLB: L'ange aux ailes déployées enlève l'éphod de l'Aaron noir.

SRC: — דיר גלוסט זיך איבערשפּאַן, האָ ?
NLLB: Vous vous trompez, hein ?

SRC: אַציגט זעט ער די לבנה מיט זײַן גלעזערן אויג. אויף דעם אַנדערן העננט אַ שלאָס. דער זילבערנער שליסל איז ניט מער אויף דער וועלט.
NLLB: Un jour, il voit la lune avec son œil cristallin. De l'autre côté, il y a un verrou. La clef d'argent n'est plus sur la terre.

NLLB-200 (600M)           sacreBLEU = 13.4
```

```
# TORCH
try:
```

```
    import torch
    from transformers import AutoTokenizer, AutoModelForSeq2SeqLM
    # Codes de langue NLLB adaptés à notre paire : yiddish ("ydd_Hebr") -> français ("fra_Latn")
    nom = "facebook/nllb-200-distilled-600M"
    tokenizer = AutoTokenizer.from_pretrained(nom, src_lang="ydd_Hebr")
    model = AutoModelForSeq2SeqLM.from_pretrained(nom)
    appareil = "cuda" if torch.cuda.is_available() else "cpu"
    model = model.to(appareil)

    def translator(s):
        entree = tokenizer(s, return_tensors="pt").to(appareil)
        sortie = model.generate(**entree,
                                forced_bos_token_id=tokenizer.convert_tokens_to_ids("fra_Latn"),
                                max_new_tokens=256)
        return tokenizer.decode(sortie[0], skip_special_tokens=True)

    nllb_hyps = [translator(s) for s in test_src]
    hyps_nllb_torch = nllb_hyps  # gardé pour COMET
    for s, h in zip(test_src, nllb_hyps):
        print(f"SRC: {s}\nNLLB: {h}\n")
    show_bleu("NLLB-200 (600M)", nllb_hyps, test_ref)
except Exception as e:
    print("NLLB indisponible pour cette paire de langues :", e)
    print("-> utilisez un LLM via prompt (cellule suivante) comme point de comparaison.")

# Score obtenu :
# NLLB-200 (600M)           sacreBLEU = 13.2
```

```
SRC: געפונען, געפונען! אָט איז דער חלום פון מײַן חלום – –
NLLB: Trouver, trouver! Voilà le rêve de mon rêve

SRC: כ'האָב גאָרנישט געפרעגט, נאָר דערלאָזגט אַן אָקרײַען ברויט, בײ די ראָנדן פאַרשימלט.
NLLB: Je n'ai rien demandé, mais j'ai offert un pain d'ocre, à la ronde.

SRC: מײַן נאָמען איז פעליציע פּאָזנאַנסקי. דער שרײַבער י. י. זינגער האָט מיך פאַראייביקט אין אַ ראָמאַן. אָמאָל האָב איך אויסגעזען אַנדערש. נאָר דאָס איז ניט וויכטיק – – –
NLLB: Je m'appelle Félicie Poznansky. L'écrivain Y.E. Singer m'a fait un roman. J'ai déjà été différent. Mais ce n'est pas important.

SRC: דער זונפאַרגאַנג באַלײַכט אירע קנייטשן מיטן ליכט פון גרינע גלייווערעס. זי ווערט דינער, אײַנגעשרומפּענער און זעט אויס ווי אַ מומיע פון אַן אַלט-עגיפּטישער פּרינצעסין
NLLB: Le soleil se couche et elle éclaire ses filles de la lumière des glissières vertes. Elle devient plus servante, plus éblouissante et ressemble à une mumie d'une princesse égyptienne ancienne

SRC: – מען דאַרף ניט קיין וואַסער, מען דאַרף ניט. אַ צוויי אונטערן האַרצן, אַ נאַרישקייט. ווו האַלטן מיר ? יאָ, כ'וועל מאַכן בקיצור
NLLB: Il n'y a pas besoin d'eau, il n'y a pas besoin. Un excès sous le cœur, une folie. Où me tenir ? Oui, je vais faire un résumé.

SRC: ? און אפשר איז גאָר שולדיק זײַן פאַליטרע, האַ
NLLB: Et peut-être que c'est son palette qui est vraiment coupable, hein ?

SRC: זײַנע וואַסערדיקע אויגן ווערן אויסגעפוקלט מער. גיסן זיך איבער אויף דער פאַליטרע. אַ נאַסע פלעמלדיקע ראָזקייט באַדעקט זײַן פנים.
NLLB: Ses yeux aquatiques s'ouvrent plus fort. Ils se jettent sur la palette. Une rosée flamboyante humide couvre son visage.

SRC: – – – אַי, צאַלקע, זײַן אייפערזיכטיק אין אַ קוימען... גוט, כ'וועל דיר זאָגן, ס'איז געווען
NLLB: Ah, bonheur, être éphérisé dans une cuisine... Bon, je vais te dire, c'était...

SRC: ס'נעמט וואָלקענען, רעגענען, מיט וואָרעמע באַבישע טערען. זיי, די טערען, פאַרלעשן דעם שטאָטער, פילן אַן די קאַנאַווע
NLLB: Il pleut, il pleut, avec des larmes chaleureuses de Bob. Elles, les larmes, oublient la terre, se sentent sans la toile.

SRC: קיינער באַפעלט ניט מע זאָל אויפשטיין. די ליפן, ווי אָפּגעהאַקטע פינגער, קאָנען זיך ניט באַוועגן...
NLLB: Personne ne nous ordonne de nous lever. Les lèvres, comme des doigts coupés, ne peuvent bouger...

SRC: ס'האָט זיך דערהערט אַ שטעפּער פֿון אַ קוילנזאַרפֿער, וואָס האָט אויפגעהויבן פון זומפ אַ וואָרצל ווי אַ נאָז פון אַ העלפאַנד.
NLLB: On entendit un cri d'un coulonneur qui relevait de la soupe une racine comme un nez d'un serpent.

SRC: אויף מאָרגן, אין דוליר בלאָנדזשענש, האָב איך ענדלעך דערטאַפּט דאָס בערגל. נאָר פון מיידל איז דאָרט פאַרבליבן נאָך ווינציקער ווי פון אַ חלום.
NLLB: Le lendemain matin, dans une blonde douce, j'ai finalement atteint la montagne. Seule une fille y est restée pendant vingt ans, comme dans un rêve.

SRC: בײַם ווערן אַ פעלצל ביסטו פאַרבליבן אַ שפעלע.
NLLB: En devenant une pelle, vous restez une épaule.

SRC: אַ בײַסט בין איך געווען אין דײַנע פליגל. פון זיך אַליין פאַרשוווונדן. זיבן שטראַליקע טויבן האָבן מיך געבראַכט אַהיים.
NLLB: J'étais un hôte dans tes ailes. Je me suis disparu. Sept étoiles brillantes m'ont ramené à la maison.

SRC: וואַן כ'בין געווואָרן פאַר דיר צו גרויס, האָסטו מיר אָפּגענעבן דײַנע הענט – די צוויי אָרבל, צו פאַרלענגערן די פרײַנדשאַפט.
NLLB: Quand je suis devenu trop grand pour toi, tu m'as donné tes mains sur les deux arbres, pour prolonger l'amitié.

SRC: צו זײַנע אויערן דערטראָגט זיך אַ מממו, אַ מממו, אַ גרויליק בענקענדיקער מממו, אַ דונער מיט אָפּגעהאַקטע פליגל...
NLLB: À ses oreilles se présente une mamme, une mamme grossière, une donnée aux ailes démembrées...

SRC: – אַ גאָלדענער שלייער – ניין, ברודערקע, אַזאַ בוים דערקענט מען בײַ נאַכט. אַרום אים, זעסט, – אַ גרויסע, שוואַרצע בוים
NLLB: Non, ma sœur, on reconnaît un tel arbre la nuit. autour de lui, voici une couverture d'or.

SRC: – זעצט יאָאכים די האַק אין בוים אַרײַן. ער וועט קלעקן אָפּצוברעכן אַ סטאָדע אָקסן, טרוקן ווי פּעך,
NLLB: Il frappera et enlèvera une stade d'oiseaux, secs comme du chaume, et le jaune ramasse le jaune dans le bois.

SRC: אַ גראָע צעכוואָליעטע וואַנט, ווי אין דער וואַנט וואָלטן זיך געטרונקען וועלף, שווימט אַרויס הינטער די זײַלן פון רעגן.
NLLB: Un mur gris et déchiré, comme dans le mur, comme des loups qui se noyeraient, nage dehors derrière les branches de la pluie.

SRC: אורשוליאַ, וויפל איז דער זייגער ?
NLLB: Urchuria, quelle heure est-elle ?

SRC: דער רעגן טוט אַ זעץ אין שויב מיט זײַנע בלײַענע פויסטן.
NLLB: La pluie fait une sieste en poudre avec ses poils bleus.

SRC: זינט איך האָב געפונען דעם יינגל אויפן דעמב, איז ער געוואָרן מײַן שוואַרצאָפּל.
NLLB: Depuis que j'ai trouvé le garçon sur le toit, il est devenu mon chapeau.

SRC: און דער מענטש האָט אַרײַנגענקוקט אינעווייניק און נאָרנישט ניט געזען, ווײַל זײַן פנים איז באַקלעפט געווארן פון שפּינוועבס בײַם בייגן זיך איבערן מויל פון ברונעם.
NLLB: L'homme entre dans la maison, il regarde et il ne voit rien. Il a les yeux pleins de tristesse et il est plein de tristesse.

SRC: און דעמאָלט האָט ער פון בוזעם אויסגעפלאָנטערט אַ שטריק, זי פאַרקניפּט אַרום אַ האָק, און ווי אַ קוימענקערער אין אַ קוימען זיך אַרונטערגעלאָזן אין ברונעם.
NLLB: Et puis il a planté de la boue un plan, elle s'est enroulée autour d'un crochet, et comme un marchand dans un couloir se tourne autour dans le brun.

SRC: ערשט דאָרטן, מיט אַ קלאָפּנדיק האַרץ, און מיט אויגן ווי ווילדע מאָנבלומען, האָט ער אין ביידע הענט אַרײַנגענומען דעם אוצר און עס געהאַלטן אַנטקעגן.
NLLB: D'abord là, avec un cœur battant et des yeux comme des monneaux sauvages, il prit le trésor dans ses deux mains et le déposa.

SRC: : און ער האָט נאָך אַ מאָל אין בייַדע הענט אַרײַנגענומען דעם שאָרבן און ווי אַ הונט אַ צעשלאָגענער דערלאָזגט אַ וואָיע
NLLB: Il prend de nouveau le morceau de bois dans ses deux mains. Un chien qui ne mange pas se met à crier.

SRC: און ער האָט דערפילט, אַז דער קאָפּ, וואָס ער טראָגט שוין אַזוי פיל יאָרן אויף די אַקסלען, איז ניט זײַנער.
NLLB: Et il se rendit compte que la tête qu'il portait sur les escaliers pendant tant d'années n'était pas la sienne.

SRC: דער מלאך מיט די פּאַרסאַזשעטע פליגל טראָגט אַוועק דאָס געסל – דעם שוואַרצן אָרן.
NLLB: L'ange aux ailes déployées porte le bouclier sur le cheval noir.

SRC: ? דיר גלוסט זיך איבערשטדן, האַ –
NLLB: Tu te fais du mal, hein ?

SRC: אָציגט זעט ער די לבנה מיט זײַן גלעזערן אויג. אויף דעם אַנדערן הענגט אַ שלאָס. דער זילבערנער שליסל איז ניט מער אויף דער וועלט.
NLLB: Il voit la lune avec son œil cristallin, sur l'autre une serrure. La clé d'argent n'est plus sur la terre.
```

```
NLLB-200 (600M)          sacreBLEU = 13.2
```

Alternative / complément : COMET

sacreBLEU reste une mesure de surface. Si un modèle COMET couvre votre langue, ajoutez un score sémantique — surtout utile ici, où votre système statistique produira sans doute des phrases agrammaticales que BLEU seul ne décrit pas bien.

Remarque : pour COMET, c'est la **langue cible** (ici le français) qui compte, pas la langue source. Il est donc utilisable ici même si le yiddish n'est pas couvert, et on peut l'appliquer à tous les systèmes.

```python
try:
    from comet import download_model, load_from_checkpoint
    model_path = download_model("Unbabel/wmt22-comet-da")
    comet_model = load_from_checkpoint(model_path)

    # COMET est calculé pour chaque système, sur les mêmes 30 phrases de test.
    # Une cellule en échec (ex. pipeline absent avec Transformers 5) laisse sa variable indéfinie : le système est alors sauté.
    systemes = {
        "Mot-à-mot": baseline_hyps,
        "IBM Model 1 + canal bruité": system_hyps,
        "NLLB-200 (Transformers)": globals().get("hyps_nllb_transformers"),
        "NLLB-200 (Torch)": globals().get("hyps_nllb_torch"),
    }
    for nom, hyps in systemes.items():
        if hyps is None:
            print(f"{nom:28s} COMET non calculé (traductions indisponibles)")
            continue
        data = [{"src": s, "mt": h, "ref": r} for s, h, r in zip(test_src, hyps, test_ref)]
        out = comet_model.predict(data, batch_size=8, gpus=0)
        print(f"{nom:28s} COMET = {out.system_score:.3f}")
except Exception as e:
    print("COMET indisponible :", e)
```

```
Mot-à-mot                    COMET = 0.385
```

```
IBM Model 1 + canal bruité   COMET = 0.374
```

```
NLLB-200 (Transformers)      COMET = 0.574
```

```
NLLB-200 (Torch)             COMET = 0.578
```

11. Bilan — questions pour votre compte-rendu

1. Comparez les trois scores sacreBLEU obtenus (mot-à-mot, IBM Model 1 + canal bruité, NLLB/LLM).
2. Donnez 3 exemples de phrases de votre corpus où votre système échoue, et reliez chaque échec à une hypothèse précise de IBM Model 1 (ordre des mots ? fertilité ? mot rare ?).
3. Le lexique bilingue extrait en section 6 est-il, lui, réellement utilisable ? Pour quel usage (pas forcément la traduction automatique complète) ?
4. Si vous deviez améliorer ce système sans passer au neuronal, quelle serait votre première piste (plus de données ? meilleur décodeur) ?
5. **Pour aller plus loin (optionnel) :** réentraînez avec plus d'itérations, ou sur un sous-ensemble plus grand de votre corpus — le score sacreBLEU de votre système progresse-t-il, et jusqu'où ?

Réponses

Question 1. Comparaison des trois scores sacreBLEU

Système	sacreBLEU	COMET
Mot-à-mot	2,8	0,38
IBM Model 1 + canal bruité	1,3	0,37
NLLB-200 (Transformers / Torch)	**13,4** / 13,2	0,57 / 0,58

On constate que **NLLB est loin devant** (13,4 en sacreBLEU, 0,57 en COMET), alors que les deux autres systèmes restent sous 3 en sacreBLEU et sous 0,4 en COMET. Néanmoins, **un score de 13 reste modeste**, et cela se voit dans les sorties du modèle, du moins celles en français. En effet, si la plupart des traductions de NLLB sont fluides, elles contiennent parfois des erreurs (p. ex. « une stade d'oiseaux »). De manière inattendue, le **canal bruité** fait moins bien que le mot-à-mot (1,3 contre 2,8), et le score COMET va dans le même sens (0,37 contre 0,38 pour le mot-à-mot, et 0,57 pour NLLB).

Cependant, il ne faudrait pas oublier que 1) IBM Model 1 représentait l'état de l'art en **1993** et que la traduction automatique a fait des bonds de géant depuis et que 2) la **taille du jeu de test est réduite** (30 phrases) et que quelques phrases erronées ont donc un fort impact sur le score global.

Évaluation par un LLM juge (`Claude Sonnet 5.5`) pour l'évaluation qualitative et sémantique des sorties

Évaluer la justesse des paires du lexique ou la qualité d'une phrase en yiddish nécessite de comprendre le yiddish et ses nuances. L'évaluation qualitative et sémantique a donc été confiée à un LLM utilisé comme juge (« **LLM-as-a-Judge** »), pratique courante en évaluation de traduction, bien que non dénuée de limites. Les consignes données au juge et ses verdicts détaillés figurent en annexes 1 et 2.

Juge

- Modèle : `claude-sonnet-5-5` (Claude Sonnet 5.5, Anthropic).
- Mise en œuvre : instances distinctes lancées comme sous-agents depuis Claude Code, sans outil ni accès à la conversation. Les 36 paires ont été soumises en deux lots (22 et 14 paires) ; une troisième instance a servi au diagnostic de trois sorties du système (voir question 2 et annexe 1).

Échantillon : 36 paires, construites à partir du lexique de la section 6 (pour chaque mot français, le mot yiddish qui maximise t(f|e)) :

- 18 paires du lexique **tirées au hasard** (`random.seed(0)`) : 6 de probabilité haute (≥ 0,9), 6 de probabilité moyenne (0,5 à 0,9), 6 de probabilité faible (< 0,5) ;

- 10 paires du lexique **choisies à l'avance**, citées dans la réponse à la question 3 : *lune*, *rue*, *pluie*, *larmes*, *ici*, *joachim*, *ursula*, *heure*, *fer*, *dédaigné* ;
- 8 paires **de contrôle** : des paires fabriquées en associant *au hasard* un mot français de l'échantillon avec un mot yiddish. Sauf hasard heureux, il n'y a donc aucune raison pour que ces paires soient correctes ; elles permettent donc de vérifier que le juge ne répond pas « correcte » à tout. Résultat : les 8 paires de contrôle sont bien rejetées, ce qui signifie que le juge ne valide pas n'importe quelle paire.

Résultats

Catégorie	Paires	correcte	partiellement correcte	incorrecte
Lexique, probabilité haute (≥ 0,9)	13	12	1	0
Lexique, probabilité moyenne (0,5 à 0,9)	9	4	0	5
Lexique, probabilité faible (< 0,5)	6	0	1	5
Contrôles (paires tirées au hasard)	8	0	0	8

Limites :

- Le juge est un LLM : il peut se tromper en yiddish, langue peu dotée, et ses verdicts n'ont pas été relus par une personne lisant le yiddish. Il indique lui-même une fiabilité plus faible pour les locutions (notamment celle de la question 2b) et pour l'un des mots de la question 2a.
- L'échantillon est petit (28 paires du lexique, 8 paires de contrôle) et chaque paire est jugée une fois. Seules 18 des 28 paires du lexique sont tirées au hasard. Les proportions par catégorie sont donc indicatives.

Question 2

L'analyse ci-dessous est faite d'après 1) le code, 2) les traductions de référence et 3) le diagnostic du LLM juge pour le sens des mots yiddish, sans que cela n'ait été relu par une personne lisant le yiddish. Le détail mot à mot figure en annexe 3.

a) Mots rares ou absents de l'entraînement

- SRC : *שטראַליקע טויבן האָבן מיך געבראַכט אַהיים .*
- HYP : « six " voraces pupilles mansarde " … . »
- REF : « Sept colombes nimbées de rayons m'ont ramené à la maison. »

Hypothèse : Trois mots n'apparaissent jamais dans les 430 phrases d'entraînement : שטראַליקע (« rayonnantes » selon le juge), געבראַכט (« apporté ») et אַהיים (« à la maison »). Puisque le modèle n'a appris aucune traduction pour eux, leur probabilité vaut 0 pour tous les mots français. Comme tous les candidats sont à égalité, le décodeur retient les derniers mots de son vocabulaire dans l'ordre des caractères, qui sont des signes de ponctuation (« … », « " », « " »). Ces trois mots porteurs de sens sont donc rendus par « " », « " » et « … ». **Remarque** : Sur les 30 phrases de test, 85 des 506 mots source (17 %) n'apparaissent jamais à l'entraînement, et 66 (13 %) y apparaissen t une ou deux fois.

b) Un mot source ne correspond pas toujours à un seul mot cible (fertilité)

- SRC : *דער רעגן טוט אָ זעץ אין שויב מיט זשענע בלייענע פויסטן .*
- HYP : « éclair pluie reste un coup rouge carreau près moisissure plomb " . »
- REF : « La pluie cogne au carreau de ses poings de plomb. »

Selon le juge, les mots טוט אָ זעץ forment une locution (littéralement « fait un coup ») que la référence rend par le seul verbe « cogne ». La sortie « reste un coup » traduit manifestement chaque mot séparément et ne la reconstitue pas.

Hypothèse : IBM Model 1 ne modélise pas la fertilité, c'est-à-dire le nombre de mots source qu'un mot cible peut produire. De plus, le décodeur associe chaque mot source à un seul mot cible (exactement un mot français par mot yiddish) et ne peut donc pas rendre une locution de trois mots par un seul verbe.

c) Ordre des mots

- SRC : *און ער האָט דערפילט , אַז דער קאָפּ , וואָס ער טראָגט שוין אַזוי פיל יאָרן אויף די אַקסלען , איז ניט זשענער .*
- HYP : « et sauver eut ressenti tu rien étoile tête , bas sauver voûtée pommes cela pourquoi années tord les épaules , est pas " . »
- REF : « Et il a senti que la tête qu'il portait sur les épaules depuis tant d'années n'était pas la sienne. »

La sortie suit l'ordre des mots yiddish : « tête », « années » et « épaules » sont produits pour קאָפּ, יאָרן et אַקסלען, dans cet ordre, alors que la référence place « épaules » avant « années ».

Hypothèse : IBM Model 1 ne tient pas compte de la position des mots et accorde la même probabilité à tous les alignements, tandis que le décodeur conserve l'ordre de la source et produit les mots français dans l'ordre des mots yiddish.

Question 3 : Utilité du lexique bilingue

D'après les données issues du code (calcul de probabilités) et de l'analyse sémantique du LLM juge, le lexique bilingue est utilisable en tant que glossaire, à condition de fixer un seuil de fiabilité.

- Concernant **les mots fréquents et les noms propres**, les probabilités sont élevées et les paires jugées correctes (confiance haute) : *lune* (0,97), *rue* (0,98), *pluie* (0,97), *larmes* (0,96), *ici* (0,98), *joachim* (0,98), *ursula* (0,99).
- Concernant **les mots rares**, ceux-ci sont peu fiables, étant donné qu'un mot français vu une ou deux fois peut recevoir une probabilité élevée sur la base d'un nombre très limité d'exemples. Le juge déclare incorrectes, avec une confiance haute, ces trois paires portant sur des mots français vus 1 à 3 fois à l'entraînement : *heure* → זאָל (0,61), *fer* → ס'האָט (0,72), *dédaigné* → בית-עלמין (0,85). Parmi les 12 paires du lexique jugées non correctes ou partiellement correctes, 7 concernent un mot français vu une seule fois et 3 un mot vu deux fois.

Sur les 28 paires du lexique jugées, aucune des 13 paires de probabilité supérieure ou égale à 0,9 n'est jugée incorrecte (12 correctes et 1 partiellement correcte). À l'inverse, parmi les 15 paires de probabilité inférieure à 0,9, 10 sont jugées incorrectes et 4 correctes. Ainsi, fixer le **seuil à 0,9** et ne retenir que les paires de probabilité ≥ 0,9 écarte toutes les paires jugées incorrectes, au prix de perdre 4 paires correctes. Ce lexique pourrait présenter un intérêt (limité) s'il était révisé (ou du moins les paires sous le seuil de 0,9) par un expert humain capable de parler yiddish, ou pour une simple translittération des noms propres.

Question 4 : Pistes d'amélioration sans passer au neuronal

1. **Le décodeur**

Notre décodeur tire 200 combinaisons au hasard : le canal bruité n'a donc aucune garantie de faire au moins aussi bien que le mot-à-mot. Une recherche en faisceau (*beam search*), ou au minimum l'ajout systématique de la combinaison gloutonne parmi les candidats, est peu coûteuse et vérifiable rapidement.

2. **Plus de données**

430 paires d'entraînement sont très peu : IBM Model 1 s'entraîne normalement sur des dizaines de milliers de phrases, et une grande partie du vocabulaire de test est inconnue. Un corpus plus grand réduirait les mots inconnus, cause majeure des échecs (question 2a).

Question 5 (optionnelle) : Plus d'itérations ou plus de données

sacreBLEU sur les 30 phrases de test, en ne changeant que `N_ITER`.

- Mot-à-mot : déterministe
- Canal bruité (décodeur aléatoire) : moyenne de 5 tirages et (min – max).

`N_ITER`	Mot-à-mot	Canal bruité : moyenne (min – max)
1	0,1	0,1 (0,1 – 0,1)
2	1,0	1,1 (0,8 – 1,4)
5	2,5	1,9 (1,7 – 2,6)
10	2,8	1,9 (1,0 – 2,7)
20	2,8	1,8 (0,7 – 2,8)
50	2,5	1,6 (1,3 – 1,8)

Conclusion. Le score progresse très vite au début, puis plafonne : on passe de 0,1 avec une seule itération à 2,5 avec 5 itérations (mot-à-mot), puis à 2,8 avec 10 ou 20 itérations. Pour le canal bruité, les moyennes à 5, 10 et 20 itérations sont presque identiques (1,9 ; 1,9 ; 1,8) ; le décodeur, lui, est aléatoire et avec le même réglage, deux tirages peuvent donner des scores très différents (de 0,7 à 2,8 à 20 itérations). On ne peut donc pas dire que l'un de ces réglages est meilleur que les autres.

Cependant, là encore, la petite taille du corpus vient limiter la portée de nos conclusions car, avec 430 paires d'entraînement, beaucoup de mots du jeu de test sont inconnus ou trop rares pour que le modèle apprenne leur traduction, quel que soit le nombre d'itérations.

Annexes

Annexe 1 : Consignes données au LLM juge

1.1 Validation des paires du lexique

Les deux lots de paires ont reçu la consigne suivante (messages envoyés tels quels aux sous-agents ; seule la mise en forme Markdown est adaptée : les signes `<`, `>`, `[`, `]`, `*` et `_` sont protégés pour s'afficher).

> « Tu es relecteur/relectrice linguistique (yiddish <-> français) et tu agis comme JUGE dans une évaluation de lexique bilingue construit automatiquement. N'utilise AUCUN outil (pas de lecture de fichier, pas de recherche web, pas de Bash) : réponds uniquement à partir des informations ci-dessous et de tes connaissances. Ne cherche pas à deviner d'où viennent les paires.
>
> CONTEXTE. Un lexique yiddish -> français a été extrait automatiquement d'un petit corpus parallèle littéraire (roman/poèmes, yiddish avec traduction française humaine). Pour chaque paire ci-dessous, on te donne un mot français, un mot yiddish proposé comme équivalent, et jusqu'à deux phrases du corpus contenant le mot yiddish (avec la traduction française humaine de la phrase). Certaines paires sont correctes, d'autres non (ne suppose aucune proportion). Le yiddish est écrit en alphabet hébreu avec points diacritiques (orthographe YIVO) ; les phrases peuvent être tronquées.
>
> TA TÂCHE. Pour chaque paire, juge si le mot yiddish est une traduction correcte du mot français, au sens d'un équivalent de dictionnaire (une différence de flexion — singulier/pluriel, conjugaison — ne rend pas la paire fausse). Appuie-toi sur le contexte fourni ET sur tes connaissances du yiddish. Verdicts autorisés (exactement ces mots) :
>
> - "correcte" : le mot yiddish est un équivalent direct du mot français ;
> - "partiellement correcte" : sens proche mais pas équivalent exact (hyperonyme, sens secondaire, autre forme grammaticale, mot qui apparaît seulement dans la même expression/phrase) ;
> - "incorrecte" : autre sens, mot grammatical sans rapport, nom propre sans rapport, etc. ;
> - "indéterminable" : tu ne peux pas trancher avec les informations disponibles. Ajoute une confiance ("haute", "moyenne" ou "faible") et une justification d'UNE phrase en français (donne le sens du mot yiddish tel que tu le comprends). Sois honnête sur tes incertitudes : le yiddish est une langue peu dotée et tu peux te tromper ; ne valide pas une paire par politesse.
>
> FORMAT DE RÉPONSE. Réponds avec : (1) une première ligne "MODELE: <l'identifiant exact du modèle que tu es, tel que tu le connais, ou 'inconnu' si tu ne le connais pas>" ; (2) puis UN SEUL tableau JSON, sans texte autour, de la forme [{"id": 1, "verdict": "...", "confiance": "...", "justification": "..."}, ...] avec une entrée par paire, dans l'ordre ; (3) puis une ligne finale "COMPETENCE: <une ou deux phrases sur ta fiabilité en yiddish pour cette tâche>".
>
> PAIRES À JUGER : »

Chaque paire était ensuite présentée sous la forme suivante (exemple : première paire du premier lot) :

> **Paire 1**
>
> Mot français : « chêne » Mot yiddish proposé : דעמב Exemples de phrases du corpus contenant le mot yiddish (yiddish, puis traduction française humaine) :
>
> - YI : און די זעג בײַסט אײַן די ציינער אינעם דעמב און דער שניי אונטן וועלט בײַזיפט מיט פורפורנעם זעגמעל. FR : La scie plante ses dents dans le chêne et la neige se crible de sciure pourpre.

- YI : מיר טרעטן אָפּ עטלעכע שפּאַנען פון דעמב און וואַשן אויס מיט שניי די פּאַרביטערטע אויגן. FR : Nous reculons à quelques pas du chêne et lavons avec la neige fraîche l’amertume de nos yeux.

1.2 Diagnostic de trois sorties du système

« Tu es relecteur/relectrice linguistique (yiddish <-> français) et tu agis comme JUGE dans l'analyse d'erreurs d'un système de traduction automatique yiddish -> français très rudimentaire (IBM Model 1 + modèle de langue bigramme, entraîné sur un petit corpus littéraire). N'utilise AUCUN outil (pas de lecture de fichier, pas de recherche web, pas de Bash) : réponds uniquement à partir des informations ci-dessous et de tes connaissances.

TA TÂCHE. Pour chacun des 3 exemples ci-dessous, tu reçois : la phrase source en yiddish, la traduction de référence humaine en français, la sortie du système, et l'alignement position par position (le système produit exactement un mot français par mot yiddish, dans le même ordre). Fais un diagnostic mot à mot puis global :

1. Pour CHAQUE position, juge le mot français produit par rapport au mot yiddish, dans ce contexte : "correct" (traduction juste du mot), "partiel" (sens proche ou forme différente), "incorrect" (autre sens ou sans rapport), ou "ponctuation" pour un signe de ponctuation traduit par un signe identique. Donne en quelques mots le sens du mot yiddish tel que tu le comprends. Si le mot yiddish n'a pas d'équivalent à lui seul dans la référence (par exemple s'il fait partie d'une locution rendue par un seul mot français, ou si la référence l'omet), indique-le.
2. Identifie ensuite les erreurs principales de la sortie par rapport à la référence et classe-les parmi : "mot incorrect", "locution ou plusieurs mots yiddish rendus par un seul mot français (ou l'inverse)", "mot omis ou ajouté par rapport à la référence", "ordre des mots", "traduction libre de la référence (pas une erreur du système mais un écart de style)", "ponctuation", "autre". Pour chaque erreur, cite les positions concernées et explique en une phrase.
3. Donne un jugement global d'une phrase par exemple (la sortie est-elle compréhensible ? que reste-t-il du sens de la référence ?). Sois factuel, ne valide pas par politesse, et signale tes incertitudes : le yiddish est une langue peu dotée et tu peux te tromper. Ne fais aucune hypothèse sur le fonctionnement interne du système (il ne s'agit pas d'expliquer pourquoi il se trompe, mais de décrire ce qui est juste ou faux).

FORMAT DE RÉPONSE. (1) première ligne "MODELE: <l'identifiant exact du modèle que tu es, tel que tu le connais, ou 'inconnu'>" ; (2) puis UN SEUL objet JSON, sans texte autour, de la forme {"exemples": [{"n": 1, "mots": [{"pos": 1, "yiddish": "...", "produit": "...", "verdict": "...", "sens": "...", "remarque": "..."}, ...], "erreurs": [{"type": "...", "positions": [..], "explication": "..."}], "global": "..."}, ...]} ; (3) puis une ligne finale "COMPETENCE: <une ou deux phrases sur ta fiabilité en yiddish pour cette tâche>". Garde les champs "sens" et "remarque" courts (moins de 15 mots).

DONNÉES : »

Les données étaient présentées sous la forme suivante (exemple : troisième phrase) :

Exemple 3

Phrase source (yiddish) : ? הא, פאַליטערע זײַן שולדיק איז גאָר אפשר און Traduction de référence (humaine) : Et si la coupable était sa palette ? Sortie du système automatique : et maternelle est … “ son palette sans hein ? Alignement position par position produit par le système (mot yiddish -> mot français produit) :

1. און -> et
2. אפשר -> maternelle
3. איז -> est
4. גאָר -> …
5. שולדיק -> “
6. זײַן -> son
7. פאַליטערע -> palette
8. , -> sans
9. הא -> hein
10. ? -> ?

Annexe 2 : Verdicts détaillés du LLM juge

2.1 Les 36 paires jugées

Détail des verdicts (verdicts et justifications reproduits tels que rendus par le juge ; la probabilité est t(f|e)) :

Mot français	Mot yiddish	Type	t(f|e)	Verdict (confiance)	Justification du juge
ursula	אורשוליאַ	lexique, probabilité haute	0,99	correcte (haute)	אורשוליאַ est la translittération yiddish du prénom Ursula, et la traduction française de chaque phrase donne bien « Ursula ».
rue	גאַס	lexique, probabilité haute	0,98	correcte (haute)	גאַס signifie « rue », comme le montrent « de l'autre côté de la rue » et « par-dessus la rue noire ».
ici	דאָ	lexique, probabilité haute	0,98	correcte (haute)	דאָ est l'adverbe de lieu « ici », et les deux phrases le traduisent ainsi.
joachim	יאָאַכים	lexique, probabilité haute	0,98	correcte (haute)	יאָאַכים est la translittération yiddish du prénom Joachim, et la traduction française de chaque phrase donne bien « Joachim ».
vitre	שויב	lexique, probabilité haute	0,97	correcte (haute)	שויב signifie « vitre, carreau » en yiddish, ce que confirment les deux phrases.
lune	לבנה	lexique, probabilité haute	0,97	correcte (haute)	לבנה (levone) signifie « lune », et les deux phrases la traduisent par « lune ».
pluie	רעגן	lexique, probabilité haute	0,97	correcte (haute)	רעגן signifie « pluie » (regn), et les deux phrases le confirment.
main	האַנט	lexique, probabilité haute	0,96	correcte (haute)	האַנט signifie « main » en yiddish, ce que confirment les deux phrases.
larmes	טרערן	lexique, probabilité haute	0,96	correcte (haute)	טרערן est le pluriel de טרער, « larmes », confirmé par « deux larmes jumelles » et « ses larmes brûlantes ».
chêne	דעמב	lexique, probabilité haute	0,95	correcte (haute)	דעמב (demb) signifie « chêne » en yiddish, et le contexte confirme la traduction « chêne ».
souffle	אָטעם	lexique, probabilité haute	0,95	correcte (haute)	אָטעם signifie « souffle, haleine, respiration » en yiddish, ce que confirment les deux phrases.

Mot français	Mot yiddish	Type	t(f|e)	Verdict (confiance)	Justification du juge
kto	קטאָ	lexique, probabilité haute	0,93	partiellement correcte (moyenne)	קטאָ est la transcription du russe/polonais « kto » (qui) utilisée comme citation dans le texte ; c'est la même forme mais un mot étranger cité, pas un mot yiddish proprement dit.
ruelle	געסל	lexique, probabilité haute	0,92	correcte (haute)	געסל est le diminutif de גאַס (rue) et signifie « ruelle, petite rue », ce que confirment les deux phrases.
dédaigné	בית-עלמין	lexique, probabilité moyenne	0,85	incorrecte (haute)	בית-עלמין signifie « cimetière », alors que « dédaigné » correspond à פֿאַרשעמט dans la même phrase.
âme	נשמה	lexique, probabilité moyenne	0,84	correcte (haute)	נשמה signifie « âme » (hébreu נשמה), ce que confirment les deux phrases.
fer	ס'האָט	lexique, probabilité moyenne	0,72	incorrecte (haute)	ס'האָט est la contraction de « es hot » (« il/cela a »), un mot grammatical sans rapport avec « fer » (en yiddish, eyzn ou ברזל).
nom	נאָמען	lexique, probabilité moyenne	0,66	correcte (haute)	נאָמען signifie « nom », sans ambiguïté.
immense	ריזיקע	lexique, probabilité moyenne	0,65	correcte (haute)	ריזיקע est la forme fléchie de ריזיק « gigantesque, immense », qui traduit bien « immense ».
fleur	אַרום	lexique, probabilité moyenne	0,64	incorrecte (haute)	אַרום signifie « autour de » (préposition/adverbe) ; « fleur » se dit בלום ou בלימעלע, qui est le mot voisin dans la phrase.
heure	זאָל	lexique, probabilité moyenne	0,61	incorrecte (haute)	זאָל est l'auxiliaire du subjonctif ou de l'optatif (« que... », « devoir »), alors que « heure » se dit שעה ou זייגער selon le sens.
poussière	קלאַנגען	lexique, probabilité moyenne	0,55	incorrecte (haute)	קלאַנגען signifie « sons, notes » ; « poussière » se dit שטויב, qui apparaît dans les phrases (שטויבזשלן, שטויב).
danser	טאַנצן	lexique, probabilité moyenne	0,52	correcte (haute)	טאַנצן est l'infinitif « danser » (substantif טאַנץ = danse), confirmé par la phrase.
vois	זעסטו	lexique, probabilité faible	0,37	partiellement correcte (haute)	זעסטו est la forme verbale « zest-u » (tu vois) avec le pronom clitique « tu » accolé ; le sens est correct mais ce n'est pas le verbe seul (זען / זעסט).
combien	ליגן	lexique, probabilité faible	0,25	incorrecte (haute)	ליגן signifie « être couché, gésir » ; « combien » correspond à ווי פֿיל, et ליגן n'apparaît que dans la traduction « gisant ».
lancinant	שפילט	lexique, probabilité faible	0,13	incorrecte (haute)	שפילט est la forme verbale « il joue » ; « lancinant » correspond ici à נאָגנדיק (nagnd'ik, qui ronge), pas à שפילט.
délicats	רעכטע	lexique, probabilité faible	0,08	incorrecte (haute)	רעכטע signifie « droit(e) » (côté droit) ; « délicats » correspond à אײדעלע (adjectif fin, délicat).
militaire	אַמאָל	lexique, probabilité faible	0,07	incorrecte (haute)	אַמאָל signifie « autrefois, un jour, parfois » ; « militaire » correspond à סאָלדאַטסקן (de soldat) dans la phrase.
déluge	קעסל	lexique, probabilité faible	0,06	incorrecte (haute)	קעסל signifie « chaudron, marmite » ; « déluge » correspond à מבול (verbe מבולט), pas à קעסל.
main	איז	contrôle (paire tirée au hasard)	0,00	incorrecte (haute)	איז est le verbe « est » (être) ; « main » se dit האַנט, qui apparaît à côté dans la phrase.
âme	דעם	contrôle (paire tirée au hasard)	0,00	incorrecte (haute)	דעם est l'article défini à l'accusatif/datif masculin (« le/au »), et « âme » se dit נשמה ; ici דעם précède seulement « בר-מיננס ».
combien	ראָם	contrôle (paire tirée au hasard)	0,00	incorrecte (haute)	ראָם est le nom propre Romm (imprimerie Veuve & Frères Romm) et n'a aucun rapport avec « combien » (qui se dit ווי פֿיל).
déluge	איבעריק	contrôle (paire tirée au hasard)	0,00	incorrecte (haute)	איבעריק signifie « superflu, de trop » ; « déluge » se dit מבול, et l'exemple fourni ne contient pas de déluge (décalage d'alignement).
pluie	שלאַכט	contrôle (paire tirée au hasard)	0,00	incorrecte (haute)	שלאַכט signifie « bataille » (la traduction française dit « cette bataille »), pas « pluie ».
rue	וואָס	contrôle (paire tirée au hasard)	0,00	incorrecte (haute)	וואָס est le pronom relatif ou interrogatif « que/qui/quoi », tandis que « rue » se dit גאַס.
lune	זענט	contrôle (paire tirée au hasard)	0,00	incorrecte (haute)	זענט est la forme « vous êtes » du verbe זײַן, sans rapport avec « lune » (לבנה).
ici	קוקט	contrôle (paire tirée au hasard)	0,00	incorrecte (haute)	קוקט est la forme verbale « regarde » (de קוקן), alors que « ici » correspond à דאָ dans la phrase, juste à côté.

2.2 Phrases fournies au juge pour les paires citées dans la question 2

Phrases du corpus fournies au juge pour les paires citées dans la question 2 (reproduites telles qu'elles figuraient dans la consigne : phrase yiddish, puis traduction française humaine) :

Mot français	Mot yiddish	Phrases fournies au juge
pluie	רעגן	YI : גרינקייט פון מאָכיקע שטיינער אין אַ רעגן ; FR : Vert de pierres moussues sous la pluie… YI : — מענטש, וואָס טוסטו, ביסטו בלינד, זעסטו ניט אַז אין רעגן איז גאָט ? FR : — Homme, que fais-tu, tu es aveugle, tu ne vois pas Dieu dans cette pluie ?
joachim	יאָאַכים	YI : — וואָס איז געשען, יאָאַכים ? FR : — Que se passe-t-il, Joachim ? YI : — יאָאַכים, דער בוים איז אטנגעהילט אין רויך, עס טרערן מיר די אויגן. FR : — Joachim, cet arbre est voilé de fumée, les yeux me piquent.
ursula	אורשוליאַ	YI : אורשוליאַ פאַלט צו זײנע פיס מיט אַ געווײן : FR : Ursula tombe à ses pieds, en pleurs : YI : — אורשוליאַ, ניט דײַנע די זינד, קאָנסט זיך איבערצײגן. FR : — Ursula, ces péchés ne sont pas les tiens, tu peux t'en convaincre.

2.3 Diagnostic de trois sorties : décompte des verdicts mot à mot

Exemple	Phrase du jeu de test	Positions	correct	partiel	incorrect	ponctuation
1	14	22	5	2	13	2
2	21	12	4	1	6	1
3	6	10	5	0	4	1

Annexe 3 : détail mot à mot des exemples de la question 2

Pour chaque mot source : sens selon le LLM juge, nombre d'occurrences dans les 430 phrases d'entraînement, mot produit par le décodeur et trois meilleurs candidats selon t(f|e).

a) Mots rares (phrase 14 du jeu de test, huit derniers mots sur 22)

Position	Mot source	Sens selon le juge	Occurrences à l'entraînement	Mot produit	Trois meilleurs candidats selon t(f|e)
15	זיבן	sept	2	six	six (0,19), sept (0,16), septième (0,15)
16	שטראַליקע	rayonnantes, à rayons	0	“	… (0,00), ” (0,00), “ (0,00)
17	טויבן	colombes, pigeons	3	voraces	éveillent (0,06), étouffer (0,06), voraces (0,06)
18	האָבן	ont (auxiliaire)	40	pupilles	ont (0,87), pupilles (0,54), avons (0,38)
19	מיך	me	14	mansarde	mansarde (0,60), m’ (0,39), avais (0,27)
20	געבראַכט	apporté, amené	0	”	… (0,00), ” (0,00), “ (0,00)
21	אַהיים	à la maison, chez soi	0	…	… (0,00), ” (0,00), “ (0,00)
22	.	point	602	.	. (0,81), heures (0,44), bonjour (0,32)

b) Fertilité, premier exemple (phrase 21 du jeu de test, mots 3 à 5)

Position	Mot source	Sens selon le juge	Occurrences à l'entraînement	Mot produit	Trois meilleurs candidats selon t(f|e)
3	טוט	fait (verbe 'tun')	4	reste	reste (0,25), tremble (0,13), savonne (0,13)
4	אַ	un	512	un	une (0,85), un (0,69), humaine (0,45)
5	זעץ	coup, heurt	8	coup	coup (0,64), cogne (0,43), offre (0,19)

b) Fertilité, second exemple (phrase 6 du jeu de test)

Position	Mot source	Sens selon le juge	Occurrences à l'entraînement	Mot produit	Trois meilleurs candidats selon t(f|e)
1	און	et	259	et	et (0,89), vieux (0,47), propre (0,38)
2	אפשר	peut-être	2	maternelle	seriné (0,13), plainte (0,13), maternelle (0,13)
3	איז	est	118	est	est (0,72), caniveau (0,63), coffret (0,43)
4	גאַר	tout à fait, vraiment	0	…	… (0,00), ” (0,00), “ (0,00)
5	שולדיק	coupable	0	“	… (0,00), ” (0,00), “ (0,00)
6	זײַן	son, sa (possessif)	90	son	son (0,62), mettre (0,48), laisser (0,45)
7	פאַליטרע	palette	2	palette	palette (0,48), vit (0,02), âmes (0,02)
8	,	virgule	856	sans	, (0,77), tu (0,50), sans (0,40)
9	האָ	hein ? (particule interrogative)	2	hein	hein (0,81), trancher (0,02), envie (0,02)
10	?	point d'interrogation	64	?	? (0,99), kto (0,07), tu (0,05)

Chiffres complémentaires (30 phrases de test, 430 phrases d'entraînement)

Mesure	Valeur
Mots source du test (hors ponctuation) jamais vus à l'entraînement	85 sur 506 (17 %)
Mots source du test vus une ou deux fois à l'entraînement	66 sur 506 (13 %)
Mots source distincts vus une seule fois à l'entraînement	1625 sur 2618 (62 %)
Jetons « … », « ” », « “ » parmi les mots produits	87 sur 616 (14 %)
Phrases où la référence est plus longue / aussi longue / plus courte que la source	21 / 2 / 7
Longueur moyenne (en mots) : source / référence	20,5 / 22,7
Phrases où la sortie a la même longueur que la source	30 sur 30